TRƯỜNG ĐẠI HỌC BÁCH KHOA HÀ NỘI
VIỆN CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG

———————— * ————————

ĐỒ ÁN
TỐT NGHIỆP ĐẠI HỌC

NGÀNH CÔNG NGHỆ THÔNG TIN

Ứng dụng học sâu trong việc tự động xác định địa điểm du lịch nổi tiếng

Sinh viên thực hiện : **Lê Văn Mạnh**
Lớp KSVB2 – K37
Giáo viên hướng dẫn: **GV.Đinh Viết Sang**

HÀ NỘI 6-2019

LỜI CẢM ƠN

Để hoàn thành đồ án này em đã nhận được nhiều sự hỗ trợ và động viên từ thầy cô, bạn bè và đồng nghiệp.

Trước hết, em xin gửi lời chân thành cảm ơn tới thầy Đinh Viết Sang bộ môn Khoa Học Máy Tính đã định hướng cho em thực hiện đồ án từ bước chuẩn bị dữ liệu cho tới việc lựa chọn mô hình để giải bài toán mà đồ án hướng tới.

Để có điều kiện về thời gian tham gia học cũng như hoàn thành đồ án, em xin cảm ơn anh Nguyễn Minh Thành, anh Ngô Ngọc Đức cùng các anh chị em tại trung tâm SVMC đã tạo điều kiện thuận lợi cho em vừa làm việc tại công ty đồng thời tham gia học văn bằng 2.

Cuối cùng em xin cảm ơn các thầy cô tại Viện Công Nghệ Thông Tin và Truyền Thông, Đại Học Bách Khoa Hà Nội đã tận tình chỉ dạy và tạo mọi điều kiện thận lợi cho em trong quá trình em rèn luyện tại trường.

Những trải niệm tại trường sẽ là nền tảng cho em đi tiếp trên con đường sự nghiệp của mình. Em xin chân thành cảm ơn!

Hà nội ngày 09/06/2019

Sinh Viên

Lê Văn Mạnh

MỤC LỤC

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Thuật ngữ	Giải thích
CNN	Convolutional neural network	Mạng nơ-ron tích chập
FC	Full connected network	Mạng nơ-ron nhân tạo
Conv	Convolutional layer	Lớp tích chập
MaxPool	Max pooling layer	Lớp max pooling
RBF	Radial basis function	Lớp thuộc mạng lenet-5
AvgPool	Average pooling layer	Lớp average fooling

DANH MỤC BẢNG BIỂU

DANH MỤC HÌNH VẼ

CHƯƠNG 1 - MỞ ĐẦU

1.1. Nhiệm vụ của đồ án

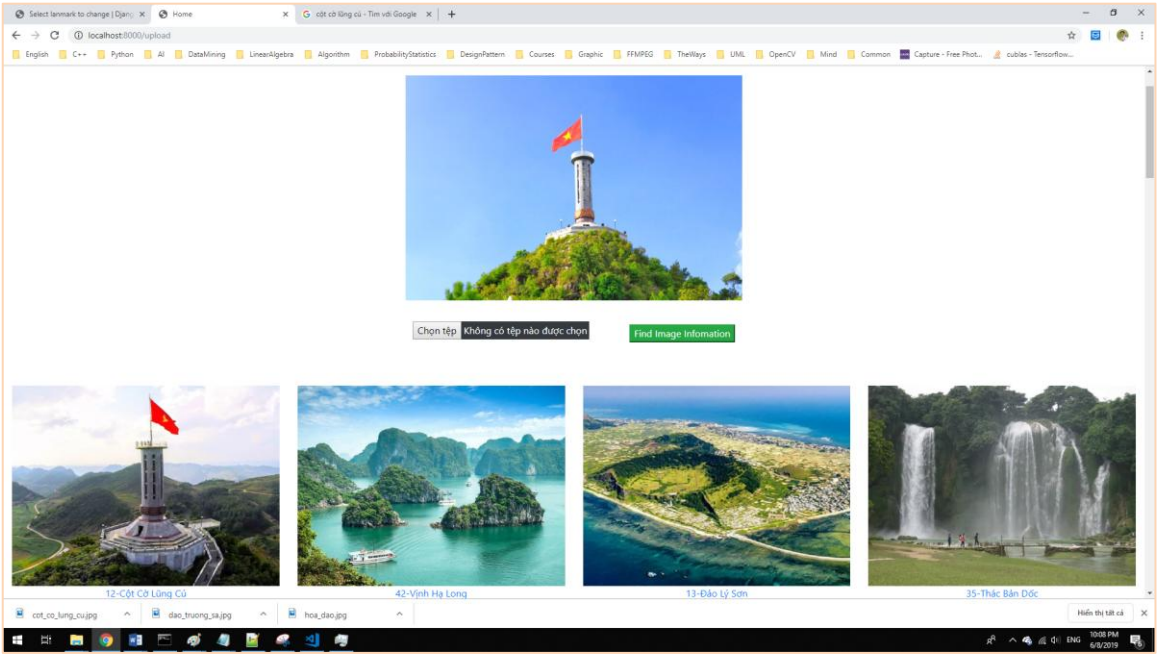

Hiện nay để biết về một địa danh hay một điểm du lịch thông thường người dùng sẽ lên các trang tìm kiếm ví dụ google.com, bing.com …và gõ từ khóa tên hoặc địa điểm du lịch muốn tới và sau đó đọc các thông tin liên quan tới địa điểm du lịch. Tuy nhiên, với sự bùng nổ của các mạng xã hội, các ứng dụng di động cùng với sự đa dạng về loại dữ liệu đặc biệt là dữ liệu ảnh. Nhiều trường hợp người dùng chỉ có một bức ảnh về địa điểm du lịch hoặc muốn tới một nơi có phong cảnh đẹp như trong bức ảnh mình đang có. Điều trên dẫn tới nhu cầu tìm kiếm thông tin địa danh thông qua hình ảnh ngày càng phổ biến.

Mục tiêu của đồ án là giải bài toán tự động xác định địa điểm du lịch thông qua hình ảnh người dùng cung cấp.

1.2. Phương pháp thực hiện

Đồ án thực hiện trên dữ liệu ảnh về các địa điểm du lịch nổi tiếng, mỗi địa danh sẽ chứa khoảng 1000 ảnh kèm với thông tin về địa lý liên quan tới địa danh đó. Do giới hạn về thời gian và nền tảng phần cứng nên hệ thống xây dựng để nhận diện địa điểm du lịch khác nhau trên lãnh thổ Việt Nam.

Với bài toán nhân diện thông tin qua ảnh việc lập trình truyền thống sẽ khó có độ chính xác cao do độ phức tạp và đặc thù của thông tin dữ liệu. Qua một thời gian tìm hiểu công nghệ, em lựa chọn phương pháp xây dựng hệ thống với phần lõi nhận diện ảnh sẽ sử dụng trí tuệ nhân tạo để đạt độ chính xác cao nhất có thể.

1.3. Ý nghĩa khoa học và thực tiễn

Người dùng khi xem ảnh có thể ngay lập tức tìm kiếm thông tin địa danh thông qua hình ảnh mình đang xem. Mọi thứ sẽ trờ lên nhanh chóng và thuận tiện cho người sử dụng góp phần thúc đẩy ngành dịch vụ và du lịch của Việt Nam.

1.4. Kết quả dự kiến

Xây dựng mạng neuron nhân tạo nhận diện 48 địa danh thông qua hình ảnh với độ chính xác trên 80%, triển khai hệ thống trên nền tảng web cho người dùng truy cập và upload ảnh lên sau đó trả lại kết quả cho người dùng trên giao diện website.

CHƯƠNG 2 – TỔNG QUAN MẠNG NƠ-RON

2.1 Mạng nơ-ron cơ bản

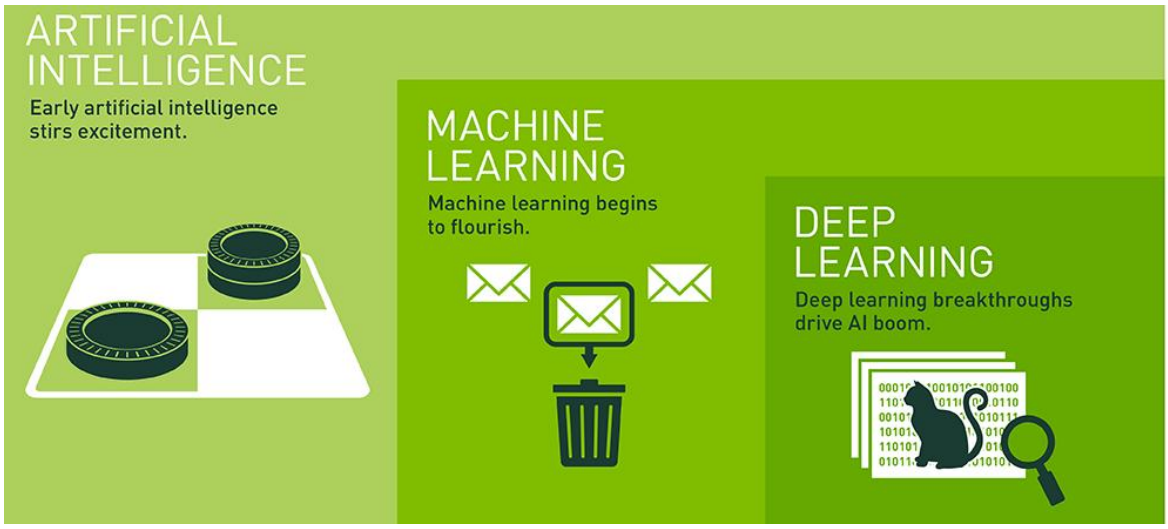

Hình 1 Tổng quan về trí tuệ nhân tạo

Trí tuệ nhân tạo là bất kỳ kỹ thuật nào cho phép máy tính để bắt chước hành vi của con người.

Học máy là tập con của trí tuệ nhân tạo, là việc máy có khả năng học mà không cần lập trình cụ thể.

Học sâu là tập con của học máy, là việc máy có thể tự trích xuất ra các đặc trưng của dữ liệu thông qua mạng nơ-ron nhân tạo. Sau đây là định nghĩa về mạng nơ-ron.

2.1.1 Cấu tạo của mạng nơ-ron nhân tạo

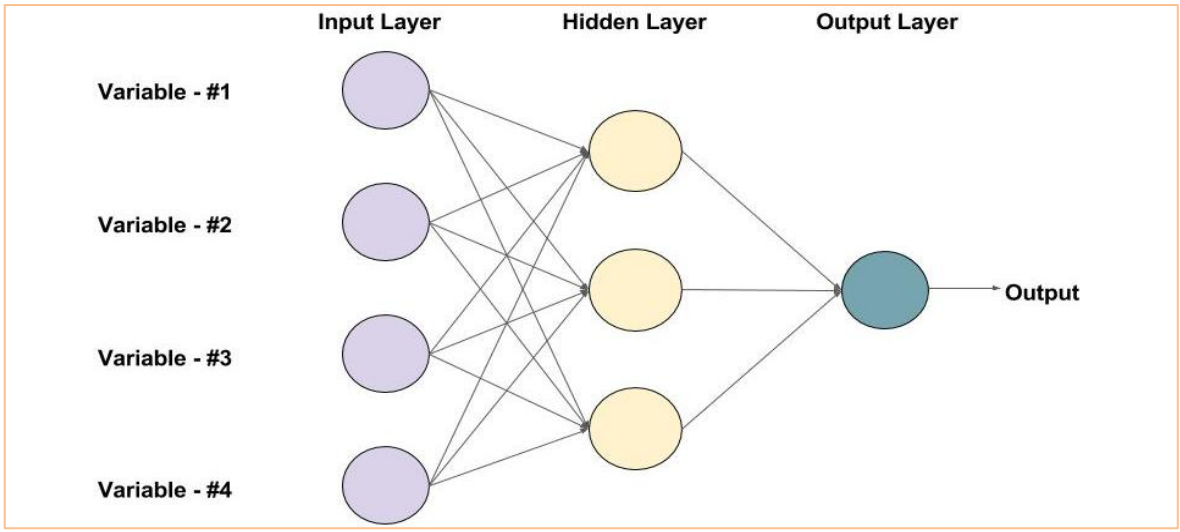

Hình 2 Mạng nơ-ron nhân tạo

Mạng gồm lớp đầu vào, lớp đầu ra và một hoặc nhiều lớp ở giữa gọi là lớp ẩn (hidden layer) các lớp được kết nối với nhau theo mô tả như hình trên. Mỗi một phần tử trong lớp ẩn gọi là một nơ-ron.

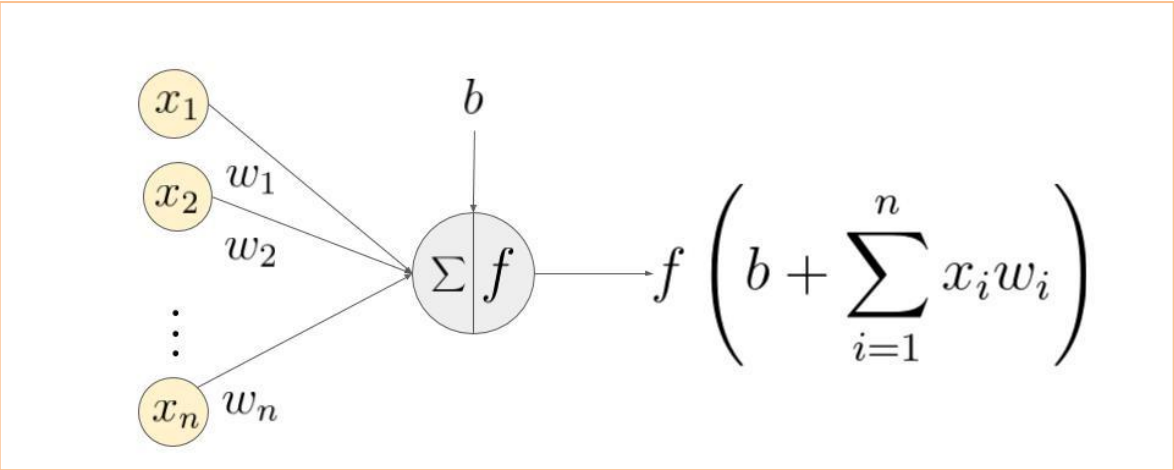

Hình 3 Nơ-ron trong mạng nơ-ron network

Một nơ-ron có đầu vào được kết nối với mọi phần tử đầu vào hoặc các nơ-ron ở lớp ẩn trước đó. Đầu ra của nơ-ron sẽ được nối với đầu ra của mạng hoặc các nơ-ron hớp lớp ẩn phía sau.

Kết quả đầu ra của nơ-ron sẽ là kết quả của hàm f được mô tả trên hình. Trong đó các giá gị x là đầu vào của nơ-ron, w là các con số đại diện cho một kết nối gọi là **weight**, b là **bias** đóng vai trò hiệu chỉnh, f là một hàm số gọi là hàm **activation**. Có nhiều hàm activation trong đó phổ biến nhất là hàm Relu.

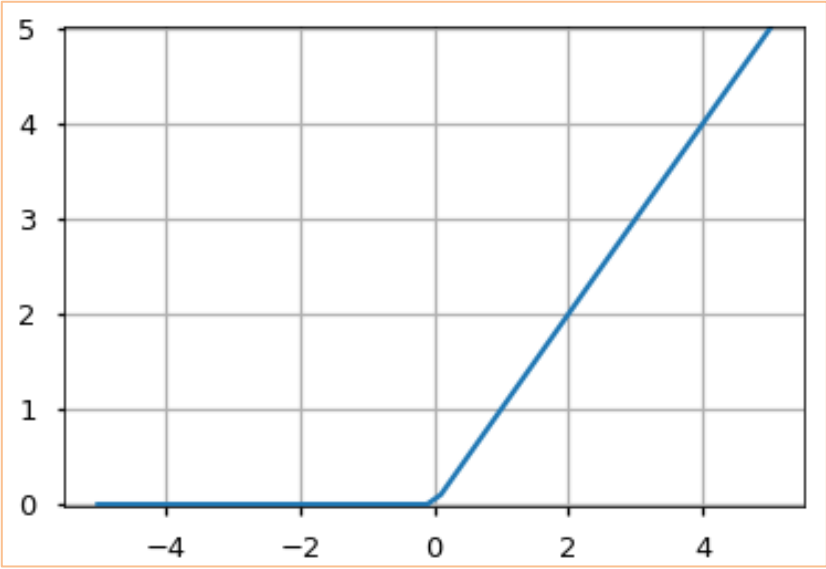

Hình 4 Hàm Relu

Giá trị đầu ra của hàm sẽ bằng giá trị đầu vào khi giá trị đầu vào lớn hơn 0. Giá trị đầu ra của hàm sẽ là 0 nếu giá trị của đầu vào nhỏ hơn hoặc bằng 0.

2.1.2 Huấn luyện mạng nơ-ron nhân tạo

+ Định nghĩa hàm mất mát: Với bài toán học có giám sát, trong quá trình huấn luyện, mạng nơ-ron nhân tạo ta sử dụng dữ liệu đã được gán nhãn sẵn, với mỗi dữ liệu đầu vào x sẽ có một nhãn tương ứng là y. Kết quả dự đoán của mạng đối với đầu vào x sẽ là $\bar{y}$. Dựa vào $\bar{y}$ và y ta thu được một hàm gọi là hàm mất mát J, hàm này sẽ là hàm số của w và b được nêu ở trên.

+ Cơ sở của việc hấn luyện mạng chính là: việc máy tìm ra các giá trị của w và b sao cho giá trị hàm mất mát (loss function) nhỏ nhất đối với một tập dữ liệu học cho trước. Để tối ưu hàm mất mát ta sử dụng thuật toán có tên gọi là **Gradient Descent**.

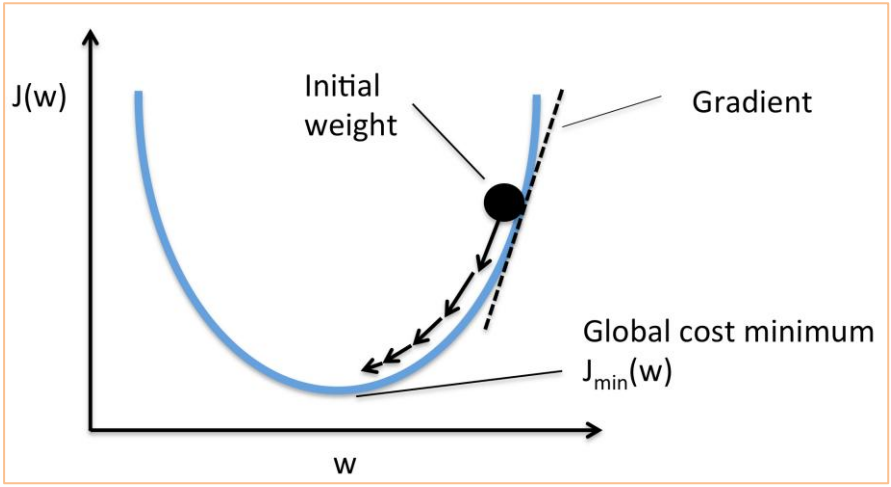

Hình 5 Minh họa thuật toán gradient descent

Trên hình minh họa việc tìm w để hàm J có giá trị nhỏ nhất, đây là trường hợp cho hàm một biết. Ban đầu, w nhận một giá trị bất kì sau khi di chuyển theo chiều ngược với chiều của đạo hàm ở điểm hiện tại thì ta luôn tìm được giá trị w sao cho hàm J có giá trị bé hơn. Lặp lại việc di chuyển theo nguyên tắc ngược chiều của đạo hàm phía trên ta sẽ tìm được w sao cho J đạt giá trị nhỏ nhất.

Vậy giả sử ta cần tìm tham số $\theta \in R^n$ để hàm mất mát J(θ) đạt giá trị nhỏ nhất ta tiến hành bước lặp như sau

$$\theta^{(k+1)} = \theta^{(k)} - \eta \nabla_\theta J(\theta)$$

Trong bài toán tối ưu mạng nơ-ron η được gọi là **learning rate**

Với hàm nhiều biến thì thay vì tính đạo hàm thông thường, ta sẽ tính đạo hàm riêng để tinh chỉnh từng biến số của hàm nhiều biến. Kết quả là sẽ thu được giá trị cho từng biến số để hàm mất mát có giá trị nhỏ nhất.

Với mạng có nhiều lớp ẩn thì việc tính giá trị đạo hàm của hàm mất mát theo từng weight và bias được thực hiện thông qua phép tính đạo hàm của hàm hợp.

$$J = g(f(x)) \Rightarrow \frac{dJ}{dx} = \frac{dJ}{df} \cdot \frac{df}{dx}$$

Có nhiều thuật toán tối ưu hàm mất mát nhưng đa số đều dựa vào nguyên lý của thuật toán gradient descent.

Quá trình để mạng tìm ra các tham số weight và bias được gọi là quá trình huấn luyện mạng nơ-ron. Kết thúc quá trình huấn luyện ta thu được tập hợp các weight và bias. Các giá trị này sẽ được lưu trong một tập tin gọi là **model** cùng với các tham số cấu hình mạng.

2.1.3 Một số thuật toán tối ưu hàm mất mát

+ Biến thể của gradient descent: Gradient descent truyền thống sẽ tính giá trị điều chỉnh tham số của một tham số cần học cho toàn bộ tập dữ liệu học.

Trong thực tế điều này trong nhiều trường hợp là bất khả thi do dữ liệu học có thể sẽ trở lên quá lớn so với tài nguyên bộ nhớ. Điều này dẫn tới việc chúng ta phải cho từng phần dữ liệu vào để huấn luyện mô hình dẫn tới hàm mất mát theo các trọng số học máy sẽ được tối ưu theo từng lần đưa dữ liệu vào (iterations) khác nhau dưới đây là hai cách huấn luyện chính.

+ Stochastic gradient descent: Là thuật toán tối ưu hàm mất mát theo từng phần tử của tập dữ liệu. Nhược điểm của phương pháp này là giá trị đạo hàm biến thiên lớn dẫn tới mạng không ổn đinh. Các tham số trong mạng có khoảng biến thiên lớn.

+ Mini Batch Gradient Descent: Thay vì dùng chỉ một phần tử đem ra huấn luyện để cập nhật giá trị cho các trọng số trong mỗi bước lặp. mạng sẽ được đưa vào một lượng các phần tử nhất định để cập nhật các trọng số. ưu điểm của phương pháp này là giảm độ lệch chuẩn của các tham số cập nhật.

+ Các thuật toán tối ưu hàm mất mát: Trong quá trình học máy, giá trị đạo hàm theo hàm mất mát sẽ biến thiên theo từng thời điểm. Có những lúc giá trị

đạo hàm rất thấp nhưng đó không phải là điểm tối ưu của hàm mất mát. Việc đặt hệ số học (learning rate) cố định cho toàn bộ các bước lặp dẫn tới việc đạo hàm lớn quá gây hiện tượng bùng nổ đạo hàm (exploding gradient) hoặc hiện tượng biến mất của đạo hàm (vanishing gradient).

Hai hiện tượng phía trên dẫn tới việc không tìm được điểm cực tiểu cho hàm mất mát. Các hàm tối ưu hiện đại sẽ giải quyết cho ta hiện tượng trên. Giá trị đạo hàm của vòng lặp sẽ phụ thuộc vào giá trị đao hàm tính được từ hàm mất mát và giá trị đạo hàm của các vòng lặp trước đó. Mộ số thuật toán tối ưu hàm mất mát là Momentum, Adagrad, AdaDelta, Adam ... trong đó thuật toán Adam được dùng phổ biến nhất.

2.1.4 Overfitting và Underfitting

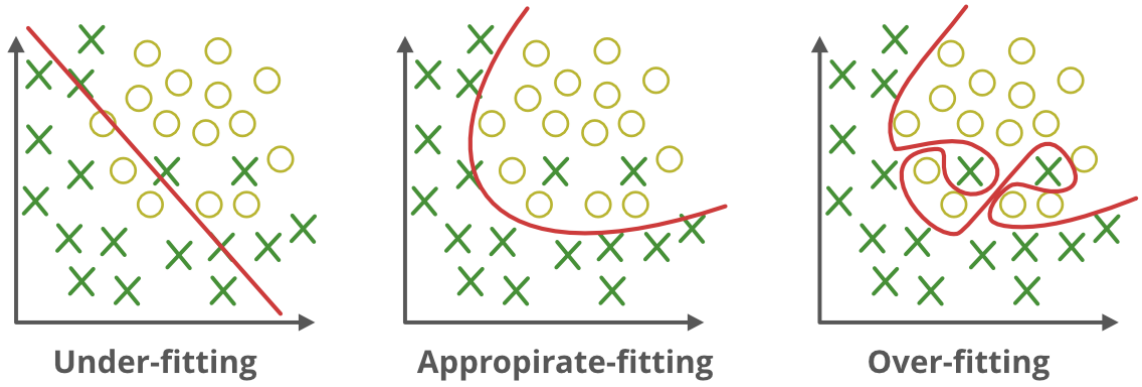

Hình 6 Overfitting và Underfitting

Underfitting là hiện tượng mạng quá đơn giản và không học được các đặc trưng của dữ liệu. Khi huấn luyện mạng thì mạng sẽ đưa ra dự đoán sai lớn trên cả tập dữ liệu học và tập dữ liệu kiểm thử

Overfitting là hiện tượng mạng quá phức tạp dẫn tới việc dự đoán rất tốt trên tập huấn luyện nhưng sai số trên tập kiểm thử lại lớn.

2.2 Mạn nơ-ron tích chập

Convolutional Neural Network (CNN – Mạng nơ-ron tích chập) là một trong những mô hình Deep Learning tiên tiến giúp cho chúng ta xây dựng được những hệ thống thông minh với độ chính xác cao như hiện nay như hệ thống xử lý ảnh lớn như Facebook, Google hay Amazon đã đưa vào sản phẩm của mình những chức năng thông minh như nhận diện khuôn mặt người dùng, phát triển xe hơi tự lái hay drone giao hàng tự động. CNN được sử dụng nhiều trong các bài toán nhận dạng các object trong ảnh.

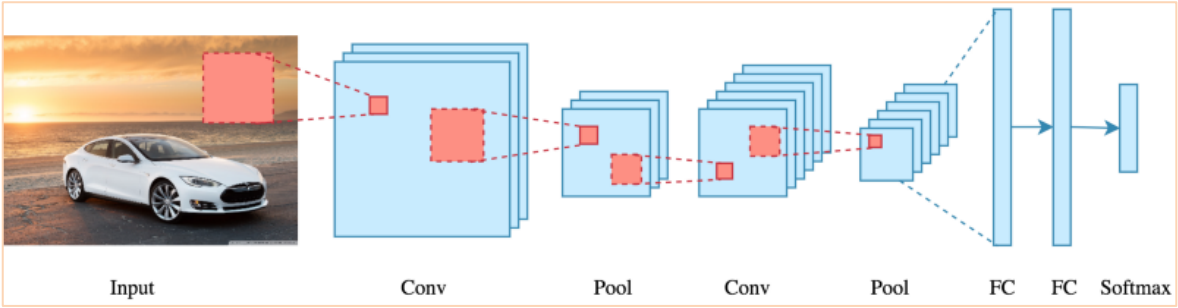

Hình 7 Sơ đồ tổng quát CNN

Sau đây là một số đặc điểm trong cách thức hoạt động của mạng CNN.

Local receptive fields: Trong mạng nơ-ron network truyền thống mỗi một nơ-ron trong input layer kết nối với một nơ-ron trọng hidden layer. Tuy nhiên trong CNN chỉ một vùng xác định trọng các nơ-ron trong input layer kết nối với một nơ-ron trong hidden layer. Những vùng xác định nêu trên gọi là Local receptive fields. Sự kết nỗi giữa input layer và hidden được chính là viêc từ Local receptive fields trên một ảnh đầu vào được biến đổi thông qua một phép toán được gọi là convolution để thu được một điểm trên hidden layer.

Shared weights và biases: Giống với mạng nơ-ron truyền thống CNN cũng có tham số weights và biases. Các tham số này được học trong suốt quá trình huấn luyện mạng và liên tục cập nhật giá trị với mỗi mẫu mới (new trainning example). Tuy nhiên, các trọng số trong CNN là giống nhau đối với mọi neural trọng cùng một lớp (layer). điều này có nghĩa là tất cả các hidden neural trong cùng một lớp đang cùng tìm kiếm trung một đặc trưng (ví dụ như cạnh của ảnh) trong các vùng khác nhau của ảnh đầu vào.

Activation và pooling: Activation là một bước biến đổi giá trị đầu ra của mỗi neural thông qua việc sử dụng một số hàn ví dụ hàm ReLU. Giá trị thu được sau phép biến đổi là giá trị dương nhất có thể của output, trong trường hợp ouput mang giá trị âm thì giá trị nhận được là 0.

pooling là một bước nhằm giảm số chiều của ma trận, cách thức phổ biến nhất là từ một vùng trên ma trận ta chọn ra số có giá trị lớn nhất làm kết quả thu được sau bước pooling (max pooling)

2.2.1 Định nghĩa convolution

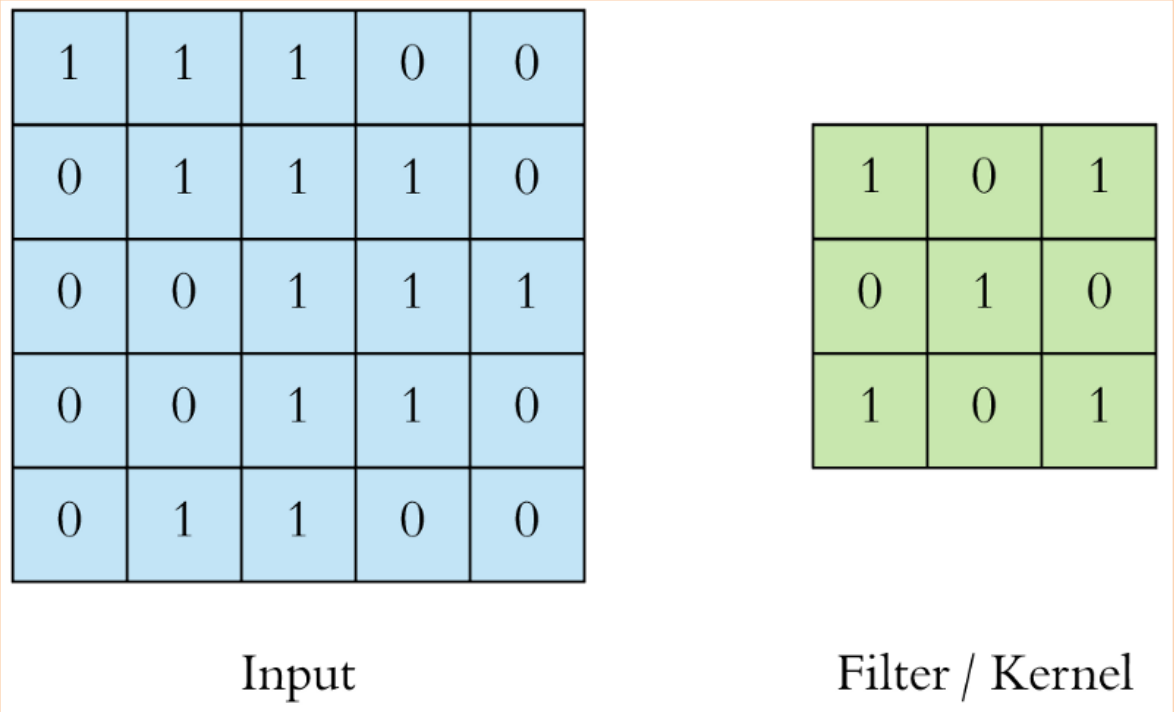

Hình 8 Khái niệm convolutional

Khối cơ bản tạo lên CNN là các lớp tích chập (convolutional layer). Convolution là một phép toán học để kết hợp hai khối thông tin với nhau. Trong trường hợp này, convolution được áp dụng trên dữ liệu đầu vào (ma trận) và sử dụng một mặt lạ gọi là convolution filter để tạo ra một mảng mới gọi là feature map.

Việc thực hiện phép toán convolution được mô tả như hình dưới dây với đầu vào là một mảng hai chiều 5x5 phần tử là filter có kích thước là 3x3 phần tử. Của sổ filter sẽ được trượt từ trái qua phải, từ trên xuống dưới. Tại mỗi vị trí của cửa sổ filter ta thực hiện nhân tương ứng từng phần tử trong ma trận đầu vào với từng phần tử trong filter, sau đó cộng tổng các tích với nhau ta thu được kết quả là một phần tử trên feature map. Quá trình thực hiện được mô tả trong hình minh họa sau đây.

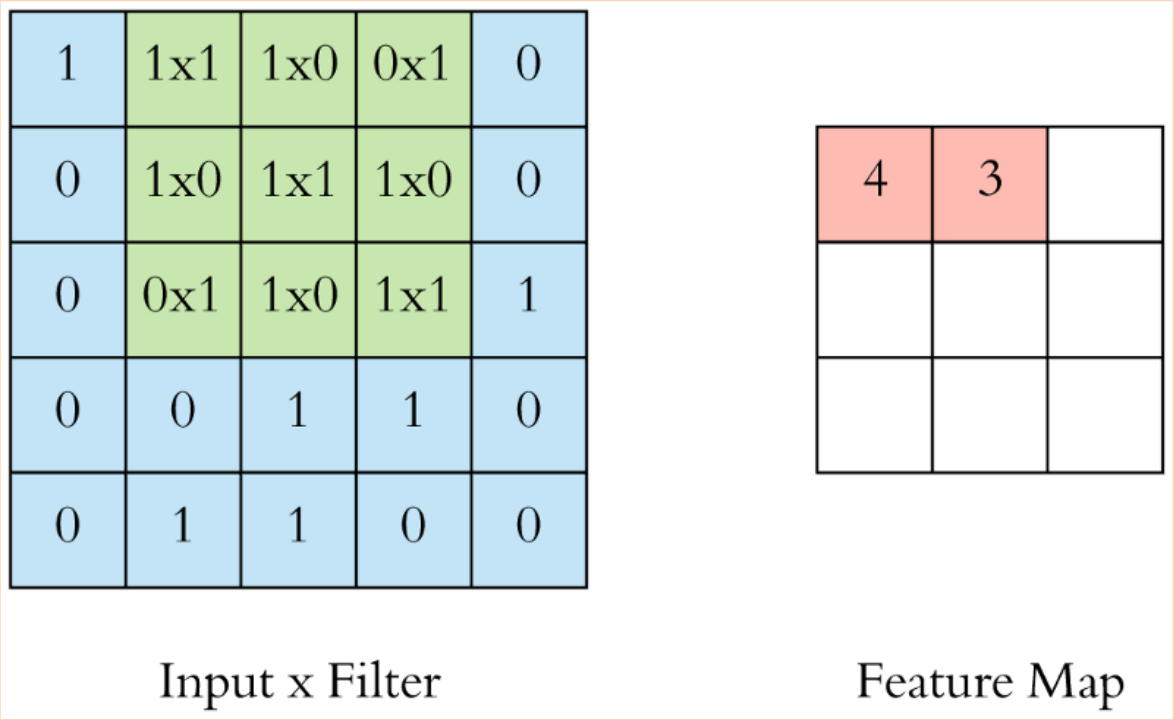

Hình 9 Convolutional và mảng hai chiều

Trên đây là mô tả thực hiện phép toán convolution với ma trận hai chiều với một filter duy nhất. Trong thực tế đối với ảnh RGB ta thực hiện convolution với ma trận ba chiều ví dụ như ảnh RGB. Với cùng một ảnh đầu vào ta áp dụng phép toán convolution với nhiều filter khác nhau. Mỗi một filter được áp dụng cho ta một feature layer. Nhiều feature layer xếp trồng lên nhau ta thu được một convolution layer. Ví dụ sau thể hiện ảnh có kích thước 32x32 và có ba kênh màu, ta sử dụng 10 filter và thu được convolution layer là một ma trận 32x32x10.

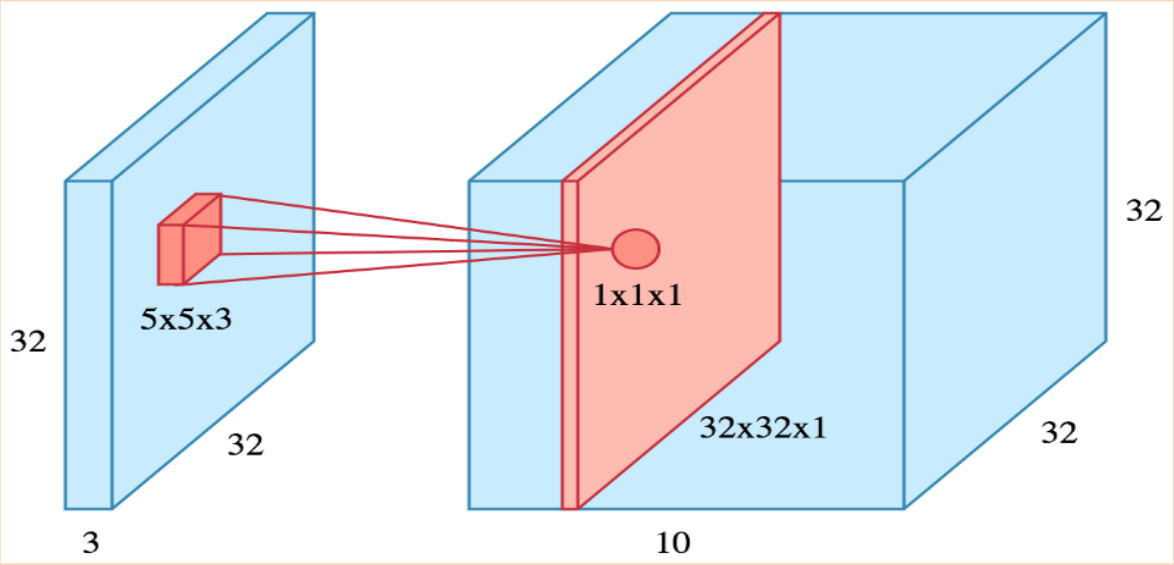

Hình 10 Convolutional và mảng ba chiều

2.2.2 Định nghĩa stride và padding

Stride là số bước nhảy của mỗi lần dịch chuyển convolution filter, trong ví dụ đầu tiên về convolution ta nhận thấy kích thước của feature map nhỏ hơn kích thước của ma trận đầu vào. Để kích thước của feature map bằng kích thước của ma trận đầu vào ta cần phải bổ xung thêm một số điểm bao quanh ma trận đầu vào thường là thêm các phần tử 0 vào xung quanh ma trận đầu vào, thao tác trên được gọi là padding.

Khi thực hiện phép toán convolution với đầu vào là ma trận vuông có kích thước là nxn, stride là s, kích thước filter là fxf, vùng padding có kích thước là p ta có kích thước của feature map thu được là:

$$Output\ size = \left(\frac{n+2p-f}{s}+1\right) x \left(\frac{n+2p-f}{s}+1\right)$$

2.2.3 Lớp pooling trong mạng CNN

Sau khi thực hiện phép toán convolution chúng ta thường sử dụng pooling nhằm giảm số chiều của dữ liệu. Loại pooling thông dụng nhất là max pooling tức là trong một vùng được chọn (pooling window) được chọn của ma trận, ta lấy phần tử có kích thước lớn nhất, cũng giống với convolution thì pooling window cũng được định nghĩa kích thước (size) và bước nhảu (tride). Dưới đây là ví dụ việc áp dụng max pooling sử dụng 2x2 window và stride là 2.

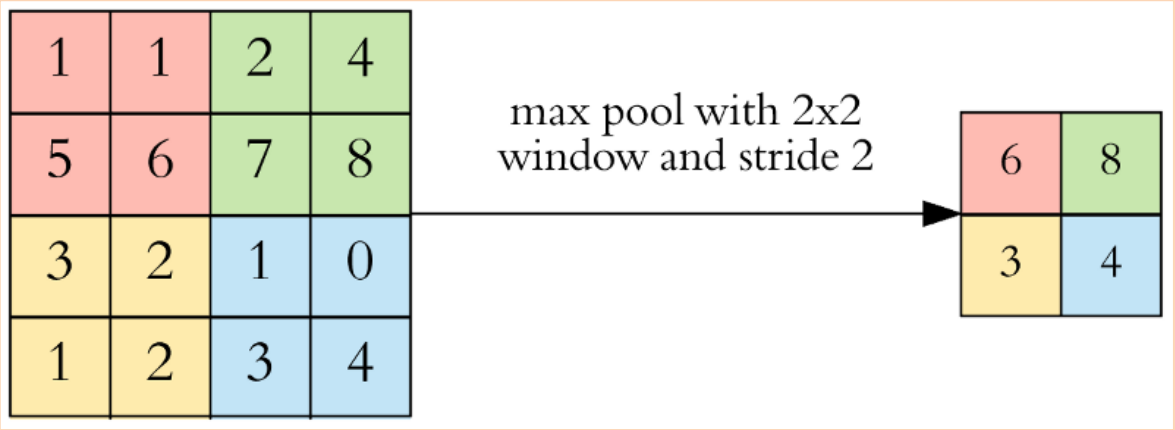

Hình 11 Minh họa max pooling

Các lớp phía sau cùng FC viết tắt của fully connected neural, chính là các lớp ẩn trong mạng nơ-ron truyền thống. Cuối cùng đầu ra thường được cho qua hàm có tên là softmax. Hàm này có tác dụng chuyển một vector đầu vào thành một vector đầu ra có cùng kích thước, các phần tử nằm trong khoảng 0 và 1, tổng các phần tử sẽ có giá trị là 1. Trong bài toán phân loại ảnh thì giá trị đầu ra của softmax chính là sác xuất rơi vào mỗi loại tương ứng khi đem một ảnh làm đầu vào của mạng để dự đoán.

2.3 Một số kiến trúc mạng CNN phổ biến

2.2.1 Kiến trúc mạng LeNet-5

LeNet-5 là một mạng cổ điển và cơ bản nhất cho bài toán nhận diện ảnh, được ứng dụng cho bài toán nhận diện số và chữ viết tay với đặc điểm dữ liệu đầu là ảnh có độ chi tiết đơn giản và kích thước nhỏ. Kiến trúc được công bố trong bài báo của Y. Lecun, L. Bottou, Y. Bengio and P. Haffner vào năm 1998.

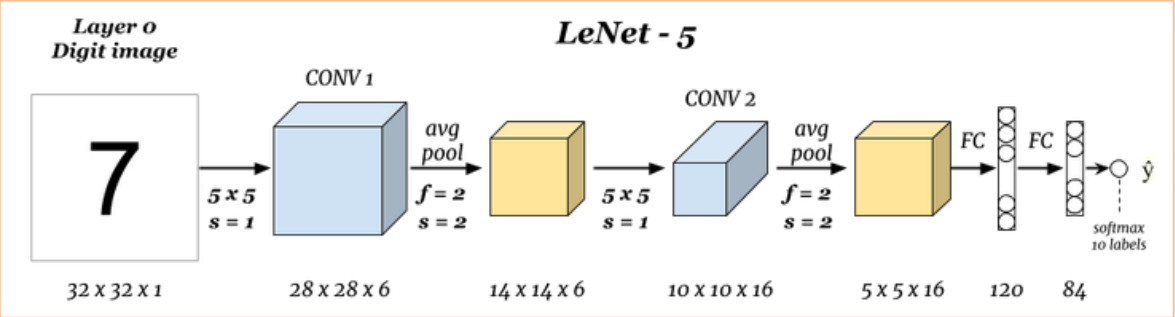

Hình 12 Sơ đồ kiến trúc mạng LeNet-5

Sau đây là bảng tóm tắt kiến trúc của mạng, gồm các lớp cùng với các tham số cần phải học tương ứng.

Layer	Filters	Biases	Stride	Tensor	Parameteres
Input	0	0	0	32x32x1	0
Conv-1	5x5x1x6	6	1	28x28x6	156
MaxPool-1	2x2	0	2	14x14x6	0
Conv-2	5x5x6x16	16	1	10x10x16	2416
MaxPool-2	2x2	0	2	5x5x16	0
FC-1	400x120	120	0	120	48120
FC-2	120x84	84	0	84	10164
RBF	0	0	0	10	0
Total					60856

Bảng 1 Kiến trúc mạng LeNet-5

Đầu vào là ảnh Gray với kích thước 32x32 pixel và đâu ra là khoảng các Euclidean giữa mỗi vector đầu vào vector trọng số tức tensor đầu ra của FC-2.

Ta có thể thấy đâu là mạng rất đơn giản với kích thước đầu vào cũng như số lượng các tham số phải học nhỏ. Tiếp theo chúng ta tìm hiểu một kiến trúc phổ biến khác nhưng phức tạp hơn mạng LeNet-5.

2.2.2 Kiến trúc mạng AlexNet

Mạng AlexNet. Dùng để phân loại 1000 loại ảnh có kích thước 227x227x3. Kiến trúc được công bố bởi Alex Krizhevsky, Geoffrey Hinton, and Ilya Sutskever vào năm 2012

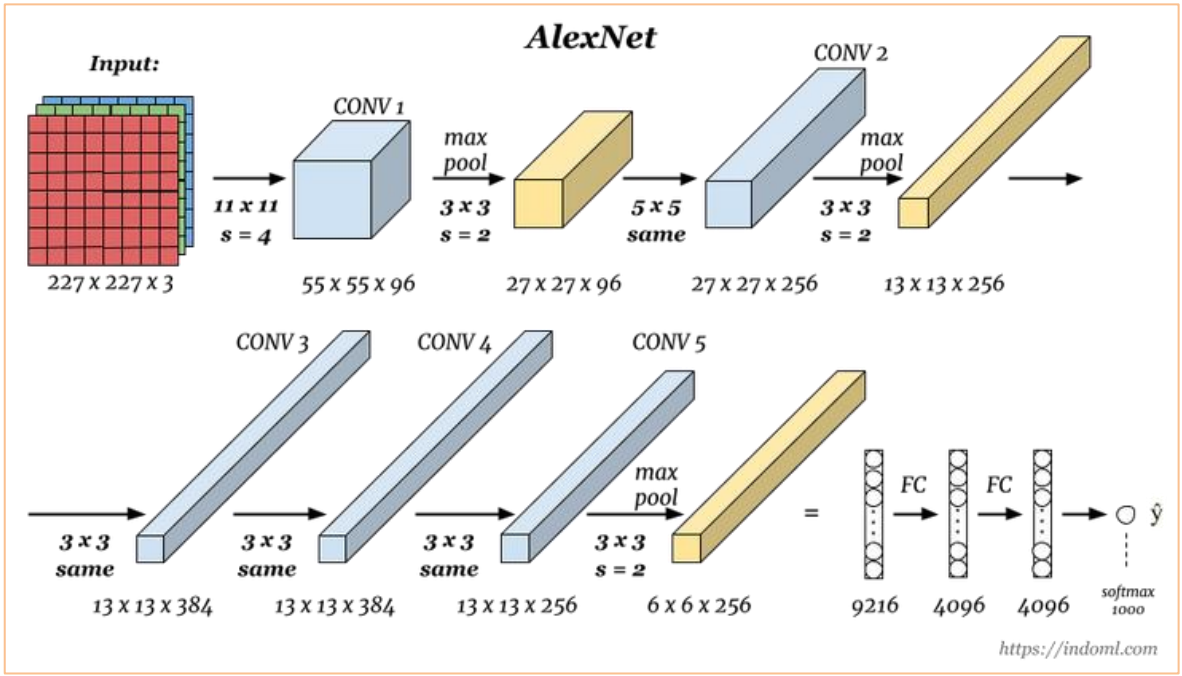

Hình 13 Sơ đồ kiến trúc mạng AlexNet

Sau đây là bảng tóm tắt các thông số của mạng chứa thông tin về kích thước tensor đầu ra của từng lớp cùng với số lượng tương ứng các tham số mà mạng cần phải học.

Layer	Filters	Biases	Stride	Tensor	Parameteres
Input	0	0	0	227x227x3	0
Conv-1	11x11x3x96	96	4	55x55x96	34944
MaxPool-1	3x3	0	2	27x27x96	0
Conv-2	5x5x96x256	256	1	27x27x256	614656
MaxPool-2	3x3	0	2	13x13x256	0
Conv-3	3x3x256x384	384	1	13x13x384	885120
Conv-4	3x3x384x384	384	1	13x13x384	1327488
Conv-5	3x3x384x256	256	1	13x13x256	884992
MaxPool-3	3x3	0	2	6x6x256	0
FC-1	9216x4096	4096	0	4096	37752832
FC-2	4096x4096	4096	0	4096	16781312
FC-3	4096x1000	1000	0	1000	4097000
Output	0	0	0	1000	
Total					62378344

Bảng 2 Kiến trúc mạng AlexNet

Mạng với đầu vào là ảnh có kích thước 227x227x3 và kết quả đầu cần thực hiện là phân loại 1000 ảnh khác nhau, tổng số tham số cần phải học của mạng là 62378344 lớn hơn so với mạng LeNet-5. Các trọng số được cập nhập thông qua quá trình tranning mạng bởi thuật toán backpropagation.

2.2.3 Kiếm trúc mạng VGG-16

Mạng VGG-16 được công bố trong bài báo của Karen Simonyan and Andrew Zisserman vào năm 2014.

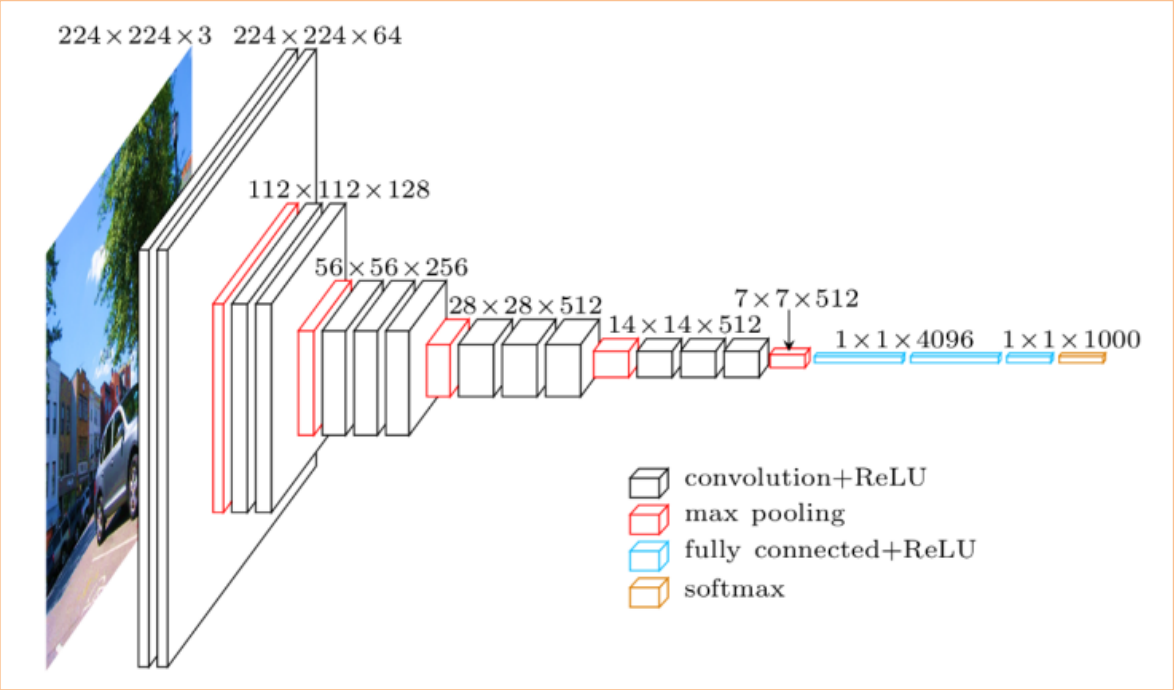

Hình 14 Sơ đồ kiến trúc mạng VGG16

Thông tin các tham số về mạng được mô tả trong bảng sau, với đầu vào của mạng là ảnh RGB và đầu ra là vector chứa 1000 phần tử tương ứng với 1000 class được phân loại.

Layer	Filters	Biases	Stride	Tensor	Parameteres
Input	0	0	0	224x224x3	0
Conv-11	3x3x3x64	64	1	224x224x64	1792
Conv-12	3x3x64x64	64	1	224x224x64	36928
MaxPool-1	2x2	0	2	112x112x64	0
Conv-21	3x3x64x128	128	1	112x112x128	73856
Conv-22	3x3x128x128	128	1	112x112x128	147584
MaxPool-2	2x2	0	2	56x56x128	0
Conv-31	3x3x128x256	256	1	56x56x256	295168
Conv-32	3x3x256x256	256	1	56x56x256	590080
Conv-33	3x3x256x256	256	1	56x56x256	590080
MaxPool-3	2x2	0	2	28x28x256	0
Conv-41	3x3x256x512	512	1	28x28x512	1180160
Conv-42	3x3x512x512	512	1	28x28x512	2359296

Conv-43	3x3x512x512	512	1	28x28x512	2359296
MaxPool-4	2x2	0	2	14x14x512	0
Conv-51	3x3x512x512	512	1	14x14x512	2359296
Conv-52	3x3x512x512	512	1	14x14x512	2359296
Conv-53	3x3x512x512	512	1	14x14x512	2359296
MaxPool-5	2x2	0	2	7x7x512	0
FC-1	25088x4096	4096	0	4096	102764544
FC-2	4096x4096	4096	0	4096	16781312
FC-3	4096x1000	1000	0	1000	4097000
Soft-max				1000	0
Total					138354984

Bảng 3 Kiến trúc mạng VGG16

Ta có thể thấy số lượng các tham số phải học trong mạng VGG16 với cùng một đầu ra là 1000 class đã lớn hơn mạng AlexNet 2 lần.

2.2.4 Kiến trúc mạng ResNet

Mạng ResNet được công bố bởi Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun vào năm 2015. Đặc điểm của mạng là số lượng layer lớn, với phần tử cơ bản có tên gọi là Residual Block được mô tả trong hình dưới đây.

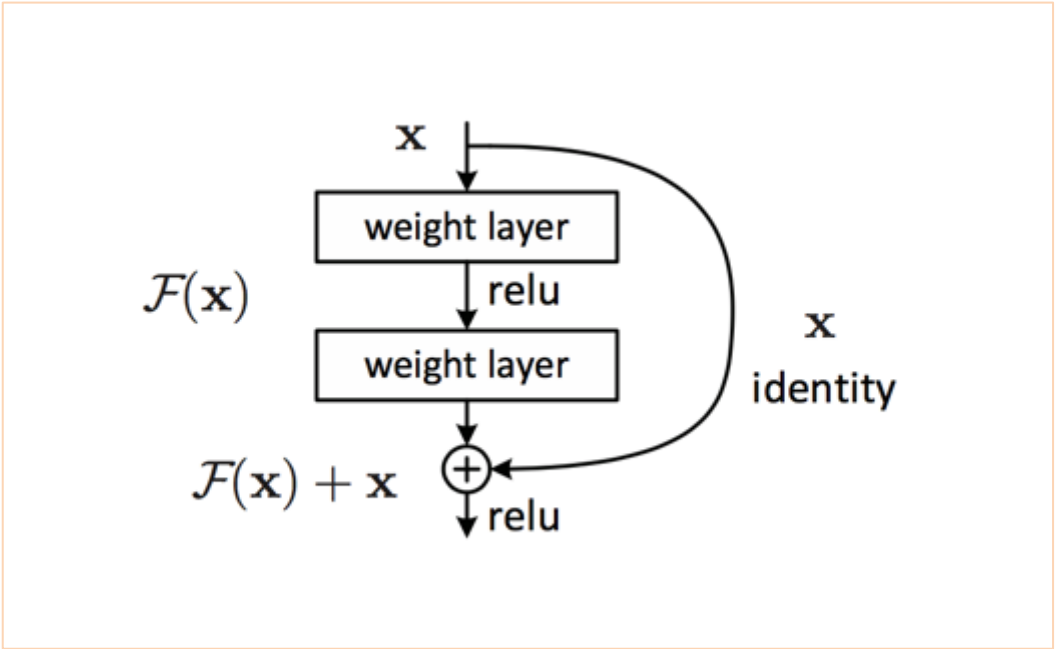

Hình 15 Sơ đồ phần tử Residual Block

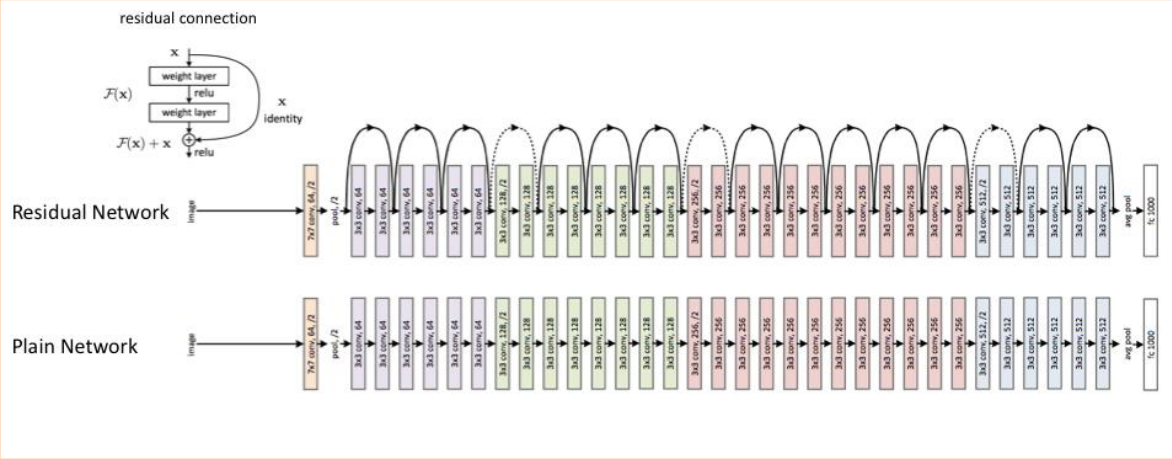

Hình 16 Sơ đồ kiến trúc mạng ResNet

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
conv2_x	56×56	3×3 max pool, stride 2				
		[3×3, 64; 3×3, 64] ×2	[3×3, 64; 3×3, 64] ×3	[1×1, 64; 3×3, 64; 1×1, 256] ×3	[1×1, 64; 3×3, 64; 1×1, 256] ×3	[1×1, 64; 3×3, 64; 1×1, 256] ×3
conv3_x	28×28	[3×3, 128; 3×3, 128] ×2	[3×3, 128; 3×3, 128] ×4	[1×1, 128; 3×3, 128; 1×1, 512] ×4	[1×1, 128; 3×3, 128; 1×1, 512] ×4	[1×1, 128; 3×3, 128; 1×1, 512] ×8
conv4_x	14×14	[3×3, 256; 3×3, 256] ×2	[3×3, 256; 3×3, 256] ×6	[1×1, 256; 3×3, 256; 1×1, 1024] ×6	[1×1, 256; 3×3, 256; 1×1, 1024] ×23	[1×1, 256; 3×3, 256; 1×1, 1024] ×36
conv5_x	7×7	[3×3, 512; 3×3, 512] ×2	[3×3, 512; 3×3, 512] ×3	[1×1, 512; 3×3, 512; 1×1, 2048] ×3	[1×1, 512; 3×3, 512; 1×1, 2048] ×3	[1×1, 512; 3×3, 512; 1×1, 2048] ×3
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

Hình 17 Thiết kế chi tiết một số mạng Resnet cơ bản

2.2.5 So sánh một số kiến trúc mạng CNN

Trên đây là một số mạng CNN phổ biến được dùng mà em đã tìm hiểu, ngoài ra còn rất nhiều kiến trúc mạng khác nữa. Nhu cầu đặt ra cần có một bảng thống kê tổng quan về độ chính xác và yêu cầu tài nguyên tính toán cho các loại mạng.

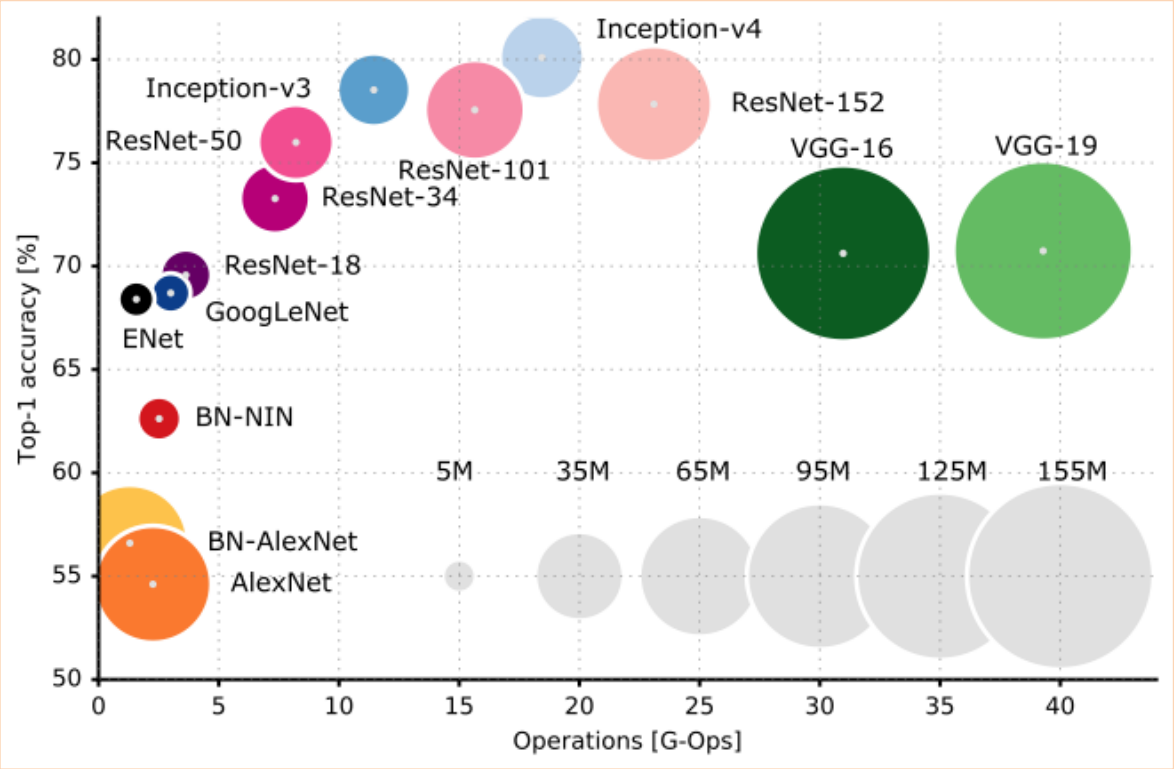

Hình 18 Độ chính xác và khối lương tính toán của một số mạng

Hình trên được lấy từ kaggle.com, chúng ta có thể thấy được sự so sánh về khối lượng tính toán và độ chính xác giữa các cách xây dựng mạng CNN phổ biến hiện nay, trong đó ResNet-50 và ResNet-34 có độ chính xác khá cao trong khi khối lượng tính toán không nhiều. AlexNet cần khối lượng tính toán thấp nhưng độ chính xác tương đối thấp so với các kiến trúc mạng khác.

Trên đây là một số kiến trúc mạng phổ biến trên thế giới đã được xây dựng và kiểm nghiệm cũng như dùng trong các cuộc thi nhận diện ảnh lớn. Dựa vào các kiến trúc đã có cũng như cơ sở lý thuyết vê machine learning em đi tiến hành xây dựng và kiểm nghiệm với mạng được tùy biến đối với bài toán cụ thể của em là nhận dạng địa danh

CHƯƠNG 3 – ỨNG DỤNG MẠNG NƠ-RON TÍCH CHẬP CHO BÀI TOÁN NHẬN DẠNG ĐỊA DANH

3.1 Triển khai mạng dựa trên kiến trúc mạng LeNet-5

Bảng thiết kế chi tiết các lớp của mạng với bài toán nhận diện địa danh.

Layer	Filters	Biases	Stride	Tensor	Parameteres
Input	0	0	0	256x256x3	0
Conv-1	3x3x3x8	8	1	256x256x8	224
MaxPool-1	2x2	0	2	128x128x8	0
Conv-2	3x3x8x16	16	1	128x128x16	1178
MaxPool-2	2x2	0	2	64x64x16	0
Conv-3	3x3x16x32	32	1	64x64x32	4640
MaxPool-3	2x2	0	2	32x32x32	0
Conv-4	3x3x32x64	64	1	32x32x64	18496
MaxPool-4	2x2	0	2	16x16x64	0
Conv-5	3x3x64x128	128	1	16x16x128	73856
MaxPool-5	2x2	0	2	8x8x128	0
FC-1	8192x256	256	0	256	2097408
FC-2	256x64	48	0	48	12336
Total					2208138

Bảng 4 Chi tiết tham số của mô hình dựa trên mạng lenet-5

Sau đây là kết quả triển khai mạng bằng tensorflow, hình ảnh trên được xuất ra bởi tensorboard

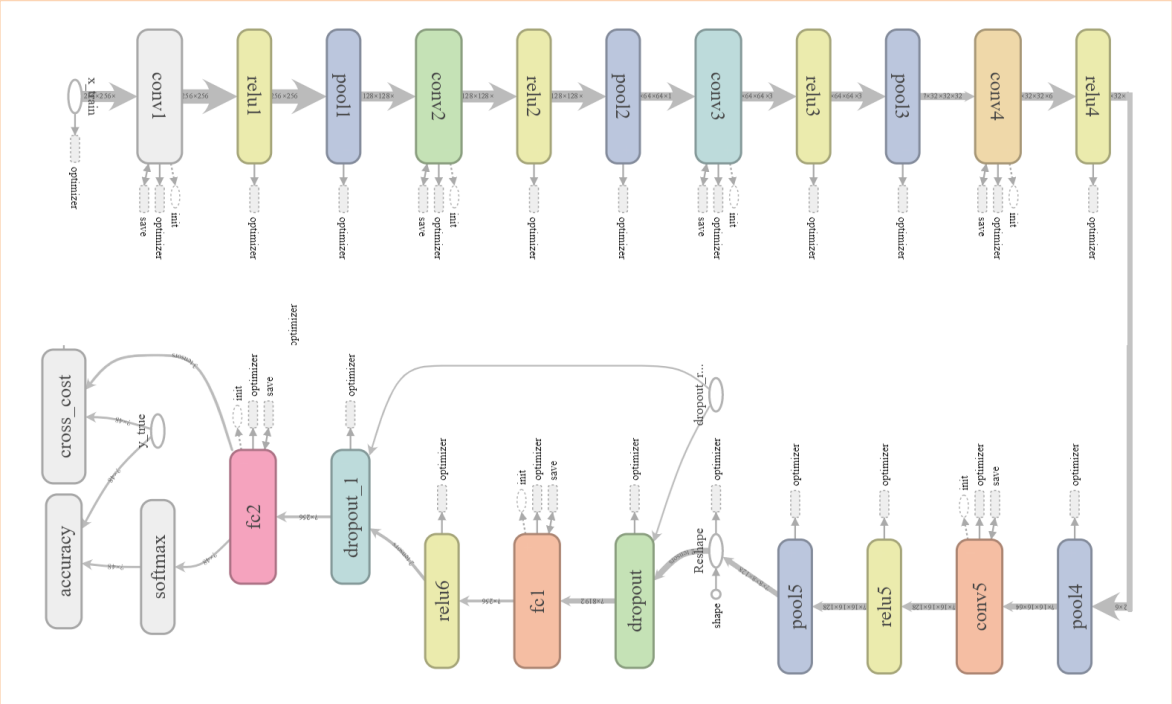

Hình 19 Mô phỏng kiến trúc mạng dựa trên mạng lenet-5

3.1 Triển khai mạng dựa trên kiến trúc mạng AlexNet

Dưới đây là tham số các lớp của mô hình triển khai dựa trên mạng AlextNet.

Layer	Filters	Biases	Stride	Tensor	Parameteres
Input	0	0	0	256x256x3	0
Conv-1	11x11x3x96	96	4	62x62x96	34944
MaxPool-1	3x3	0	2	30x30x96	0
Conv-2	5x5x96x256	256	1	30x30x256	614656
MaxPool-2	3x3	0	2	14x14x256	0
Conv-3	3x3x256x384	384	1	14x14x384	885120
Conv-4	3x3x384x384	384	1	14x14x384	1327488
Conv-5	3x3x384x256	256	1	14x14x256	884992
MaxPool-3	3x3	0	2	7x7x256	0
FC-1	12544x2048	2048	0	0	2048
FC-2	2048x2048	2048	0	0	2048
FC-3	2048x5	5	0	0	5
Total					33645957

Bảng 5 Chi tiết tham số của mô hình dựa trên mạng alexnet

Với các tính toán ở phía trên, mạng được triển khai trên tensorfow và sử dụng tensorboard để kiểm tra một cách trực quan cấu trúc của mạng.

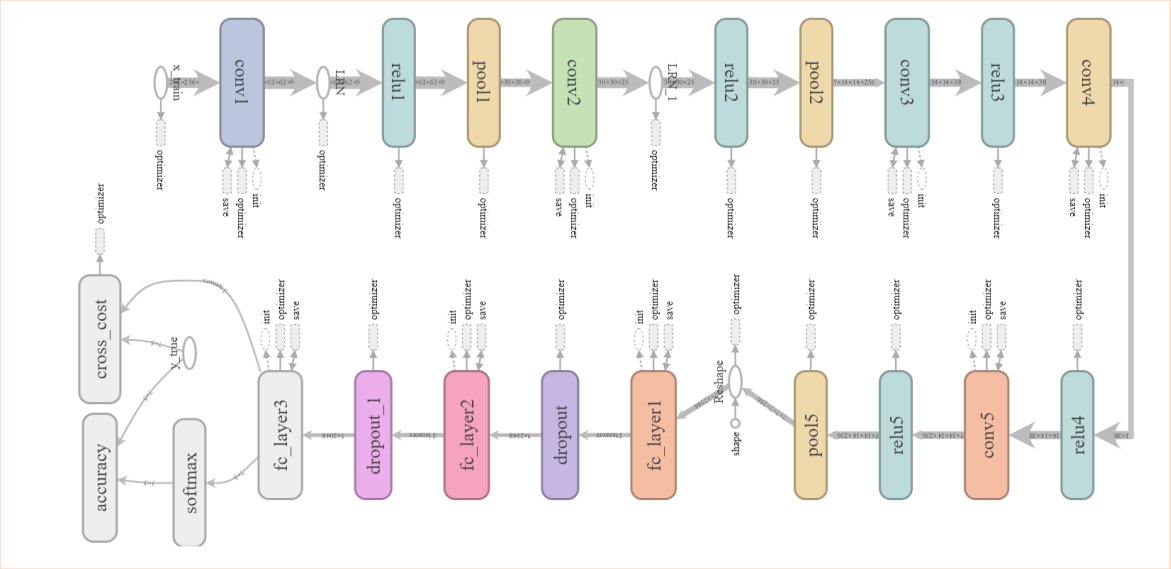

Hình 20 Mô phỏng kiến trúc mạng dựa trên mạng alexnet

3.4 Triển khai mạng dựa trên kiến trúc mạng VGG16

Dưới đây là bảng thiết kế các lớp của bài toán khi triển khai dựa trên mạng VGG16

Layer	Filters	Biases	Stride	Tensor	Parameteres
Input	0	0	0	256x256x3	0
Conv-1	3x3x3x64	64	1	256x256x64	1792
Conv-2	3x3x64x64	64	1	256x256x64	36928
MaxPool-1	2x2	0	2	128x128x64	0
Conv-3	3x3x64x128	128	1	128x128x128	73856
Conv-3	3x3x128x128	128	1	128x128x128	147584
MaxPool-2	2x2	0	2	64x64x128	0
Conv-4	3x3x128x256	256	1	64x64x256	295168
Conv-5	3x3x256x256	256	1	64x64x256	590080
Conv-6	3x3x256x256	256	1	64x64x256	590080
MaxPool-3	2x2	0	2	32x32x256	0

Conv-7	3x3x256x512	512	1	32x32x512	1180160
Conv-8	3x3x512x512	512	1	32x32x512	2359296
Conv-9	3x3x512x512	512	1	32x32x512	2359296
MaxPool-4	2x2	0	2	16x16x512	0
Conv-10	3x3x512x512	512	1	16x16x512	2359296
Conv-11	3x3x512x512	512	1	16x16x512	2359296
Conv-12	3x3x512x512	512	1	16x16x512	2359296
MaxPool-5	2x2	0	2	8x8x512	0
FC-1	32768x2048	2048	0	2048	67110912
FC-2	2048x2048	2048	0	2048	4196352
FC-3	2048x64	5	0	5	10245
Total					86029637

Bảng 6 Chi tiết tham số của mô hình dựa trên vgg16

Đề giảm số lượng tham số của mạng giúp việc huấn luyện và tối ưu mạng nhanh hơn. Em điều chỉnh số lượng nút ở các lớp thuộc mạng nơ-ron cơ bản về 2048 nơ-ron.

Sau đây là kiến trúc mạng được triển khai trong chương trình dùng thư viện tensorflow. Và được mô phỏng trên bộ công cụ tensorboard của tensorflow.

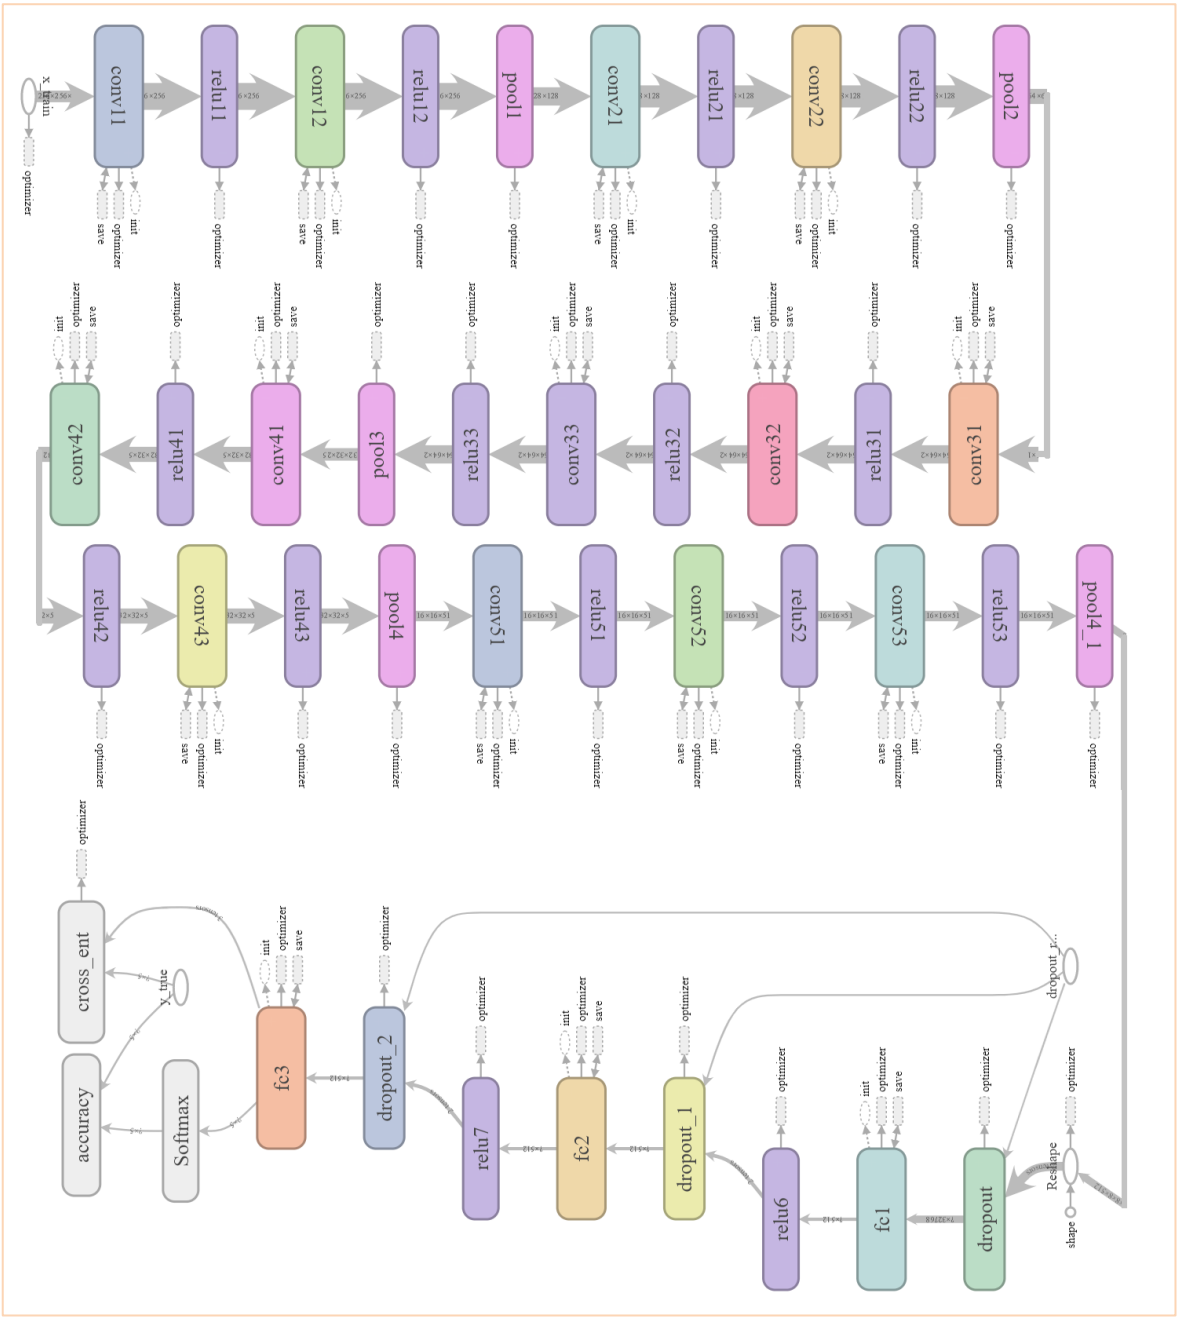

Hình 21 Mô phỏng kiến trúc mạng dựa trên mạng vgg16

3.3 Triển khai mạng dựa trên kiến trúc mạng Resnet

Dưới đây là bảng thiết kế các lớp của bài toán khi triển khai dựa trên mạng Resnet-34. Mạng resnet có nhiều phiên bản với số lượng các lớp khác nhau có thể lên tới 152 lớp. Với giới hạn của nền tảng phần cứng về bộ nhớ máy tính trong quá trình huấn luyện mạng. Em lựa chọn mạng Resnet-34 để thử nghiệm, với đầu vào là ảnh 256x256x3. Chi tiết các lớp được mô tả trong bảng sau.

Layers	Filters	Stride	Number	Tensor	Parameters
Input	0	0	1	256x256x3	0
Conv-0	7x7x3x64	2	1	128x128x64	9408
MaxPool-0	2x2	2	1	64x64x64	0
Block-2	3x3x64 3x3x64 3x3x64	1	3	64x64x64	1728
Block-3	3x3x128 3x3x128 3x3x128	1	4	32x32x128	3072
Block-4	3x3x256 3x3x256 3x3x256	1	6	16x16x256	9216
Block-5	3x3x512 3x3x512 3x3x512	1	4	8x8x512	12288
AvgPool	2x2	2	1	4x4x512	0
FC-1	4x4x512x512	512		512	4194816
FC-2	512x128	128		128	65664
FC-3	128x48	48		48	6192
Total					4266672

Bảng 7 Chi tiết tham số của mô hình dựa trên Resnet-34

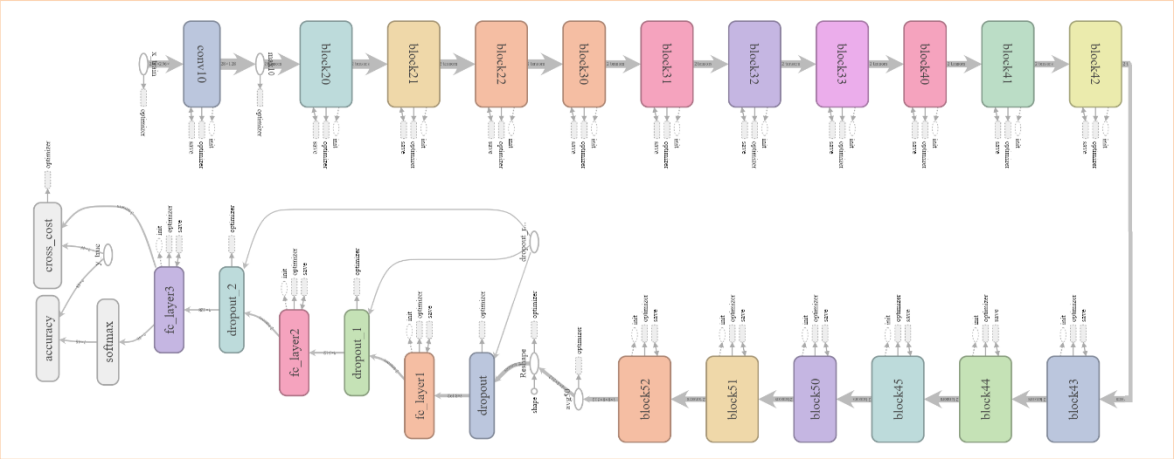

Hình 22 Mô phỏng mạng dựa trên mạng resnet-34

Trên đây là kết quả mô phỏng mạng Resnet cùng với một số mạng cơ bản nhất được đã được thử nghiệm và sử dụng trong CNN. Trong chương tiếp theo em đi tới phần chạy thử nghiệm để chọn ra kiến trúc mạng phù hợp nhất với bài toán nhận dạng địa danh.

3.5 Hàm mất mát và hàm tính độ chính xác trong quá trình huấn luyện

Hàm mất mát được sử dụng trong quá trình huấn luyện mô hình là hàm Log Loss. Hàm có phương trình như sau.

$$\text{Log Loss} = \sum_{(x,y)\in D} -y\log(y') - (1-y)\log(1-y')$$

Trong đó D là tập dữ liệu, x là đối tượng đầu vào của mạng, y là nhãn của tương ứng của dữ liệu đó, y' là giá trị dự đoán của mạng đối với dữ liệu đầu vào là x.

Độ chính xác của mô hình được đo bởi công thức

$$\text{Accuracy} = \frac{1}{N}\sum_{(x,y)\in D} equal(y', y)$$

N là số lượng phần tử trong tập dữ liệu, hàm equal trả về giá trị là 1 khi y' và y bằng nhau, trả về giá trị 0 khi y' và y có giá trị khác nhau.

CHƯƠNG 4 - THỬ NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ CỦA MÔ HÌNH

4.1 Bộ dữ liệu sử dụng cho bài toán

+ Bộ dữ liệu zalo được download từ trang https://challenge.zalo.ai dữ liệu gồm tập hợp các ảnh có kích thước 480x480x3 định dạng ảnh RGB về các địa danh du lịch nổi tiếng của Việt Nam. Bộ dữ liệu có khoảng 30000 ảnh cho 103 địa danh. Số lượng ảnh phân bố cho mỗi địa danh không đều nằm trong khoảng từ 50 đến 3000 ảnh. Trong 103 địa danh có nhiều địa danh có phong cảnh tương tự nhau ví dụ các địa danh ở vùng Tây Bắc thường có hình ảnh giống nhau mà ngay bản thân mắt người cũng khó phần biệt các địa danh đó với nhau. Trong phạm vi đồ án này em chọn ra 48 địa danh có nét đặc trưng phong cảnh đôi một khác nhau để huấn luyện mô hình.

Quá trình huấn luyện mạng sẽ chia tập dữ liệu thành hai phần, trong đó 70% dùng cho việc huấn luyện mạng và 30% dùng cho việc kiểm định độ chính xác của mạng.

Do số lượng ảnh trên mỗi địa danh phân bố không đều, để tăng độ chính xác của mô hình cần tăng số lượng ảnh cho mỗi địa danh và làm cho số lượng ảnh cho mỗi địa danh cân bằng nhau. Để giải quyết vấn đề trên cần sử dụng một số kỹ thuật augmentation.

+ Các kĩ thuật augmentation được sử dụng nhằm mục đích làm cho phong phú tập dữ liệu có sẵn ví dụ trong dataset có số lượng phần tử của mỗi loại không đồng đều hay lượng ảnh đại diện cho mỗi loại đó có số lượng ít. Một số kỹ thuật phổ biến như Flip, Rotation, Scale, Crop, Translation … Trong đồ án này em dùng kĩ thuật Crop để dữ liệu đầu vào dược cần bằng giữa các địa danh (class) khá nhau.

+ Việc huấn luyện mạng mất nhiều thời gian, nhằm chọn lựa ra mạng phù hợp nhất em sẽ cho mạng huấn luyện với số lượng đầu ra của mạng tăng dần. Dựa vào kết quả huấn luyện với việc nhận diện 5 địa danh em sẽ chọn ra mạng phù hợp nhất cho việc nhận diện 48 địa danh.

Sau khi áp dụng kỹ thuật augmentation, mỗi địa danh có 1200 ảnh dùng để huấn luyện, 400 ảnh để kiểm chứng độ chính xác.

Đường màu vàng cam biểu thị cho độ chính xác và lỗi trên tập dữ liệu huấn luyện, đường màu xanh biểu thị cho đọ chính xác và lỗi trên tập dữ liệu kiểm chứng.

Quá trình huấn luyện đều được thực hiện trên máy tính hệ điều hành window-10, CPU Core-i7, GPU 1080-TI

4.2 Kết quả huấn luyện mạng dựa trên mạng lenet-5

Để thuận tiện cho việc nhắc tới mạng này, em gọi mạng này là mạng số 1

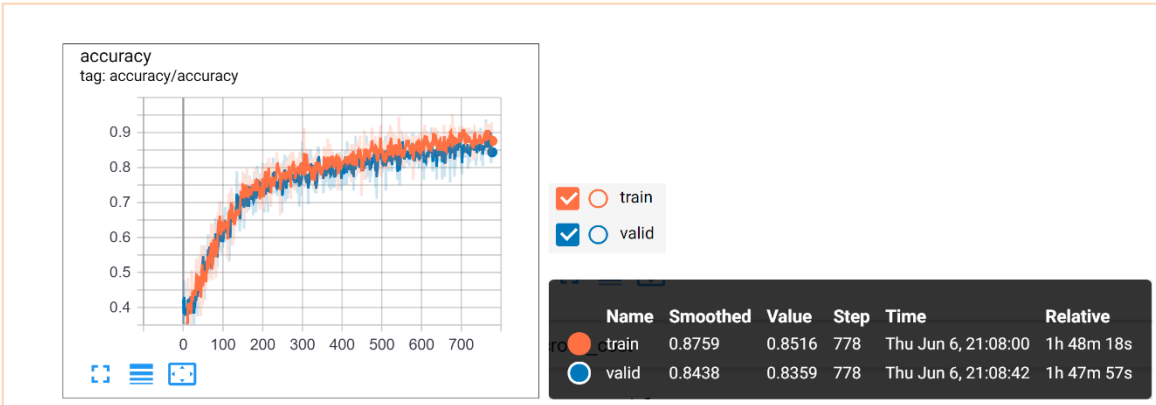

Hình 23 Độ chính xác của mạng số 1 trong quá trình nhận diện 5 địa danh

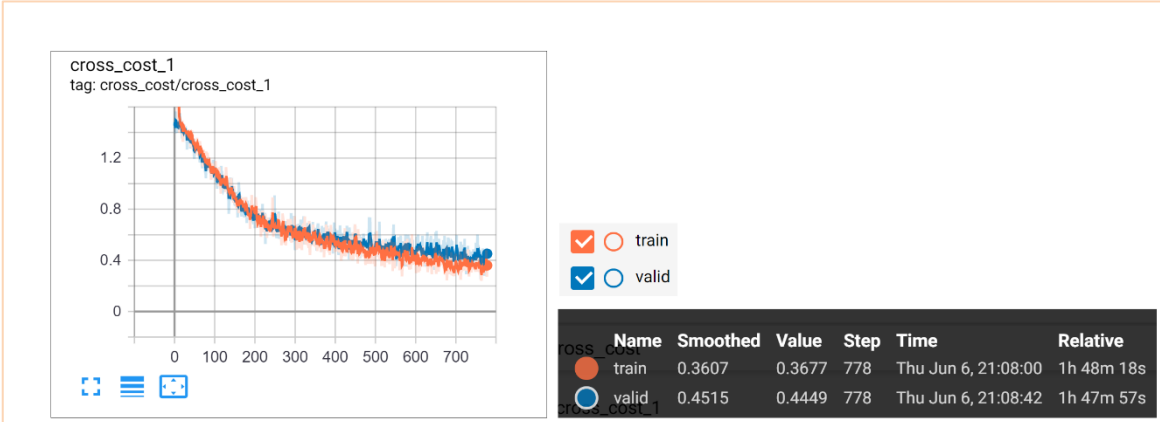

Hình 24 Giá trị lỗi của mạng số 1 trong quá trình nhận diện 5 địa danh

Trên đây là kết quả của mạng được huấn luyện với tập dữ liệu có 5 địa danh, mục tiêu của việc chọn ra 5 địa danh để huấn luyện nhằm mục đích thử nghiệm mạng.

Dữ liệu gồm có 6000 ảnh cho huấn luyện và 2000 ảnh cho việc kiểm thử chia đều cho 5 địa danh.

Số lần lặp (epoch) của quá trình huấn luyện là 51 tức là toàn bộ dữ liệu ảnh được đem vào huấn luyện 51 lần. Trong mỗi lần lặp, toàn bộ dữ liệu ảnh sẽ chia thành từng phần gọi là batch để đưa vào mạng. Kích thước của batch là 128 ảnh

Hệ số học (learning rate) là 1E-4

Thời gian huấn luyện mạng là 108 phút

Độ chính xác cuối cùng là 87% trên tập dữ liệu huấn luyện và 84% trên tập dữ liệu kiểm thử. Giá trị lỗi cuối cùng là 0.36 trên tập dữ liệu huấn luyện và 0.45 trên tập dữ liệu kiểm thử.

Chúng ta có thể thấy giá trị của độ chính xác tăng nhẫn một cách đều đặn và giá trị của hàm mất mát giảm đều đặn. Giá trị của độ chính xác và giá trị lỗi trên hai tập huấn luyện và kiểm thử gần với nhau cho thấy mạng đã được cấu hình tốt.

+ Từ kết quả trên em quyết định thử nghiệm mạng với tập dữ liệu 48 địa danh.

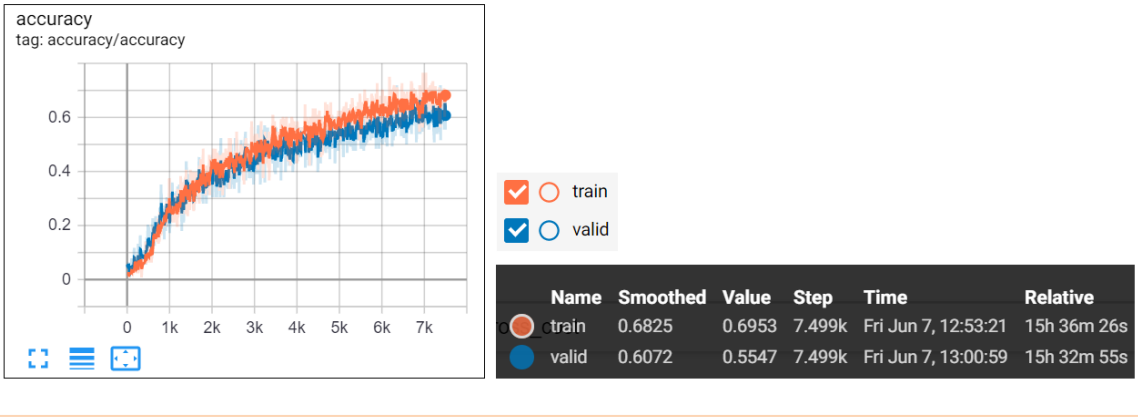

Hình 25 Độ chính xác của mạng số 1 trong quá trình nhận diện 48 địa danh

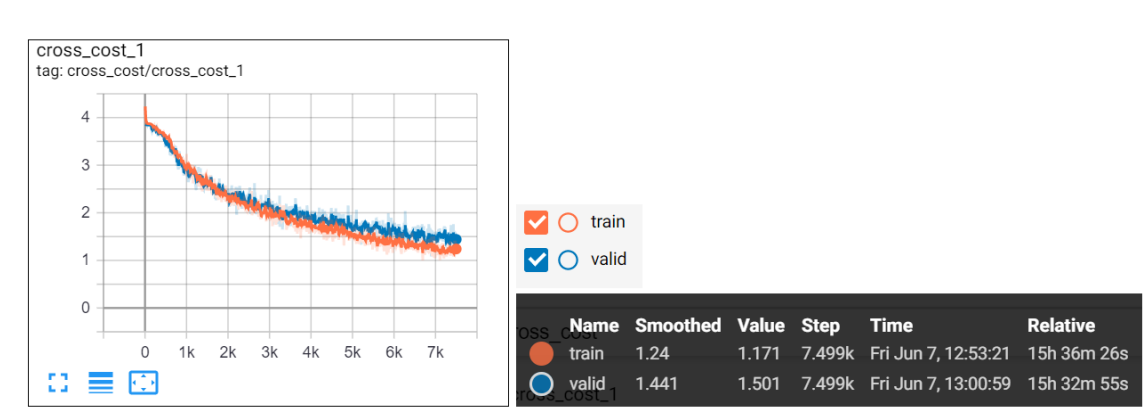

Hình 26 Giá trị lỗi của mạng số 1 trong quá trình nhận diện 48 địa danh

Số lượng ảnh gồm có 1200x48 ảnh cho huấn luyện, 400x48 cho kiểm thử.

Số lần lặp (epoch) là 50 lần. Độ chính xác cuối cùng 68% trên tập huấn luyện và 60% trên tập kiểm thử.

Thời gian huấn luyện là 15 giờ 30 phút.

Nhìn vào đồ thì có thể thấy nếu tăng thời gian huấn luyện mạng thì độ chính xác của mạng sẽ tăng. Đồ thị của lần thử nghiệm thứ hai có xu hướng giống với đồ thị thử nghiệm của lần thứ nhất cho thấy khi đã huấn luyện tốt với số lượng đầu ra nhỏ thì khả năng mạng tốt cho số lượng đầu ra lớn là cao.

4.3 Kết quả huấn luyện mạng dựa trên mạng alexnet

Để thuận tiện cho việc nhắc tới mạng này, em gọi mạng này là mạng số 2

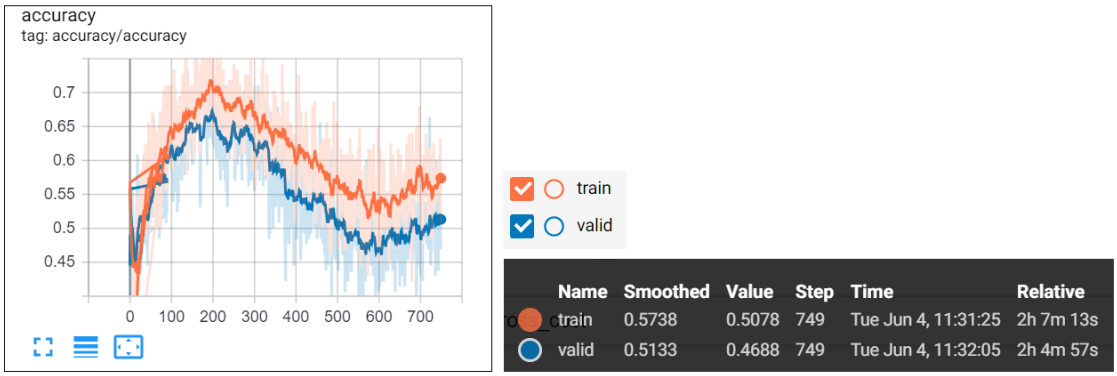

Hình 27 Độ chính xác của mạng số 2 trong quá trình nhận diện 5 địa danh

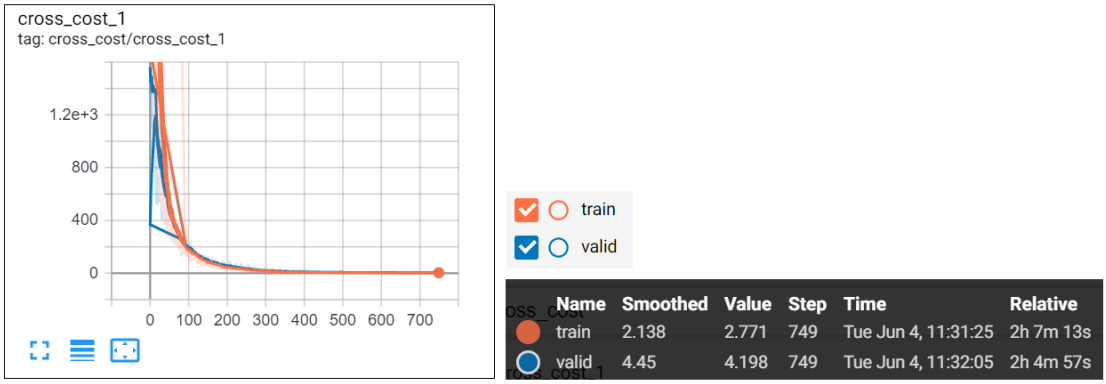

Hình 28 Lỗi của mạng số 2 trong quá trình nhận diện 5 địa danh

Kết quả cho thu được sau quá trình huấn luyện với 5 địa danh, số lượng ảnh cho huấn luyện là 1200x5 ảnh, số lượng ảnh cho kiểm thử là 400x5 ảnh.

Số lần huấn luyện (epoch) là 50 lần. Hệ số học (learning rate) là 1E-4. Đồ thị cho thấy các tham số cấu hình chưa được tối ưu, xảy ra hiện tượng bùng nổ đạo hàm. Dẫn tới độ chính xác giảm ở cuối quá trình huấn luyện.

Do thời gian huấn luyện mạng số 2 khá lâu gấp khoảng 1.5 lần thời gian huấn luyện mạng số 1.

4.4 Kết quả huấn luyện mạng dựa trên mạng vgg-16

Để thuận tiện cho việc nhắc tới mạng này, em gọi mạng này là mạng số 3

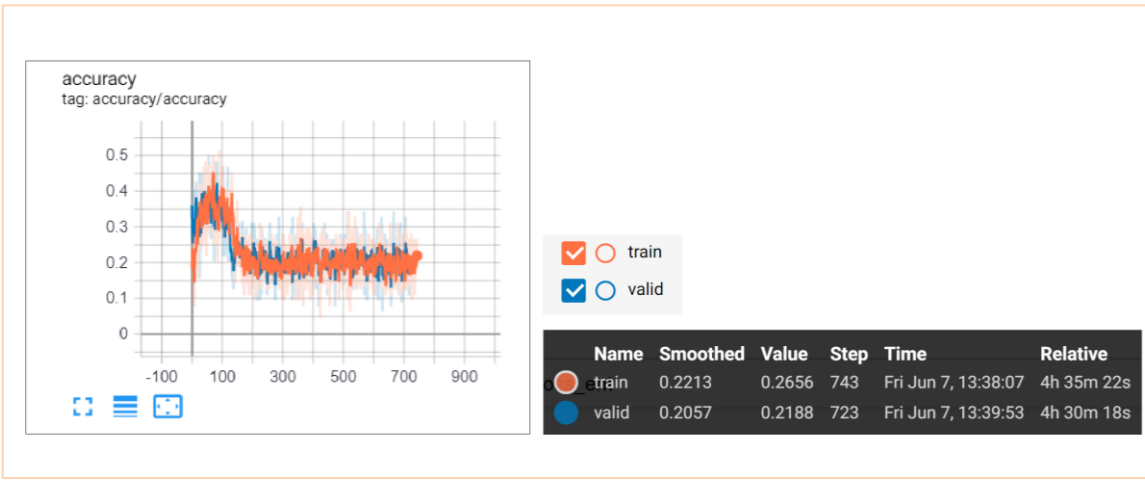

Hình 29 Độ chính xác của mạng số 3 trong quá trình nhận diện 5 địa danh

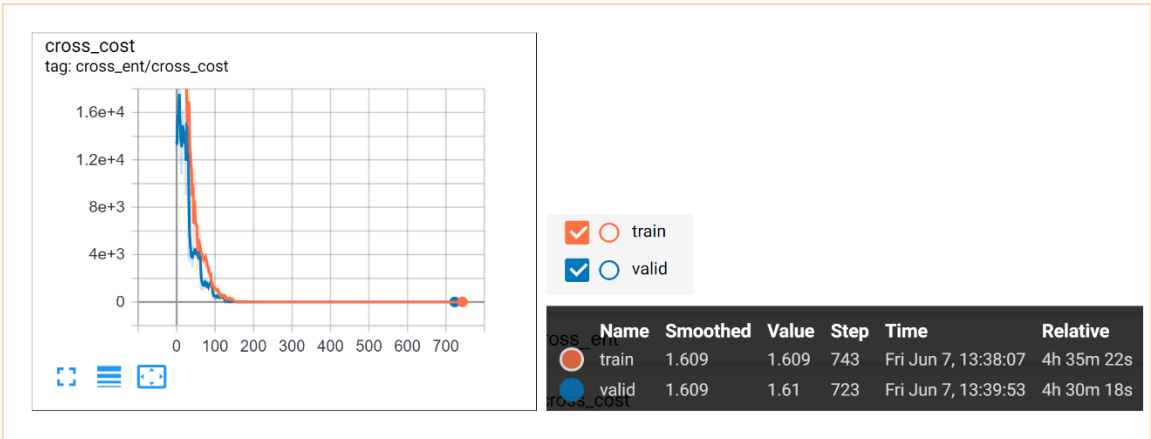

Hình 30 Giá trị lỗi của mạng số 3 trong quá trình nhận diện 5 địa danh

Trên đây là hai biểu đồ thể hiện cho giá trị độ chính xác là lỗi trong quá trình huấn luyện mạng dựa trên mạng vgg16 với việc phân loại 5 địa danh. Với 6000 ảnh huấn luyện và 1200 ảnh kiểm thử.

Hệ số học (learning rate) là 1E-4.

Mạng thực hiện khoảng 47 lần huấn luyện tên toàn bộ tập dữ liệu. Thời gian huấn luyện là 4 giờ 30 phút.

Nhìn vào đồ thị có thể thấy giá trị độ chính xác tăng nhanh thời điểm ban đầu và giảm sau đó. Trong quá trình huấn luyện mạng đã xảy ra hiện tượng bùng nổ đạo hàm dẫn tới độ chính xác của mạng bị giảm ở cuối quá trình huấn luyện. Cần giảm hệ số học xuống. Độ chính xác cao nhất của mạng rất thấp chưa tới 50% nên mạng không thích hợp cho việc tiếp tục tối ưu trong khi giới hạn về thời gian và tài nguyên.

4.5 Kết quả huấn luyện mạng dựa trên mạng resnet-34

Để thuận tiện cho việc nhắc tới mạng này, em gọi mạng này là mạng số 4

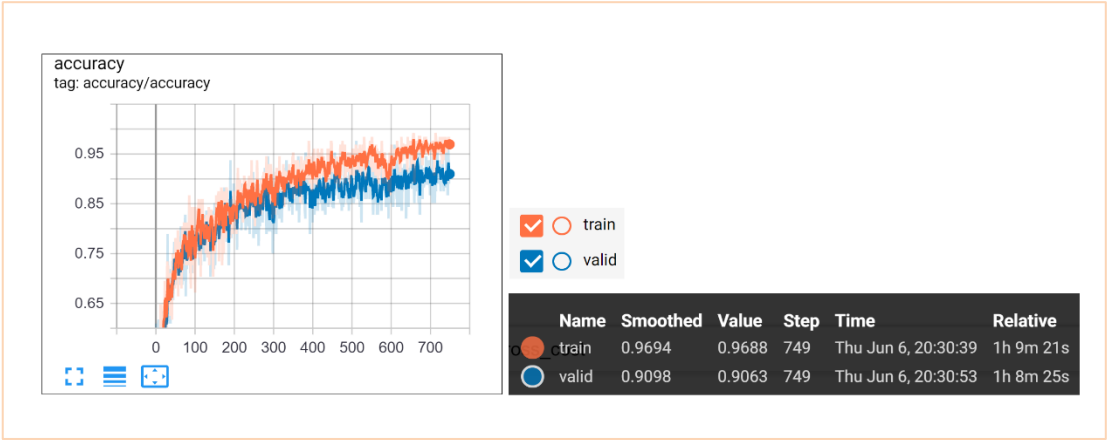

Hình 31 Độ chính xác của mạng số 4 trong quá trình nhận diện 5 địa danh

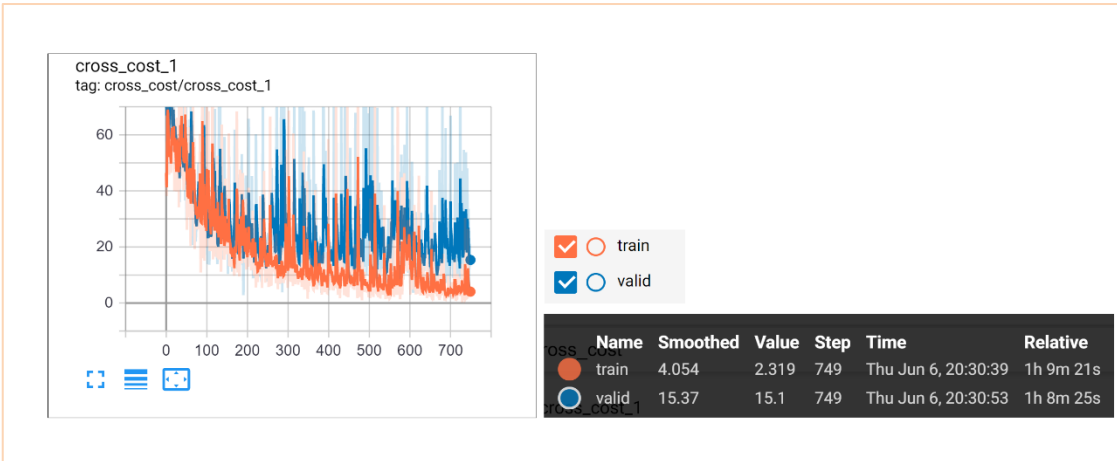

Hình 32 Giá trị lỗi của mạng số 4 trong quá trình nhận diện 5 địa danh

Số lượng ảnh và số lần huấn luyện với 5 địa danh của mạng giống với các thử nghiệm phía trên.

Đặc điểm nổi bật của mạng so với các mạng tham gia thử nghiệm là thời gian huấn luyện mạng chỉ bằng 2/3 thời gian huấn luyện mạng số 1. Cùng với việc độ chính xác trong quá trình huấn luyện của mạng tăng nhanh.

+ Sau đây là kết quả cho việc huân luyện mạng với đầu ra nhận diện 48 địa danh khác nhau.

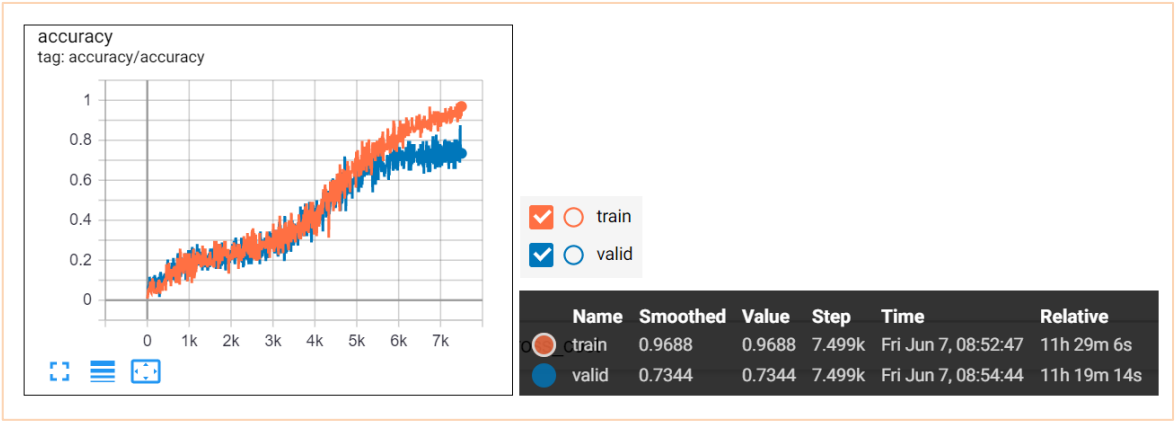

Hình 33 Độ chính xác của mạng số 4 trong quá trình nhận diện 48 địa danh

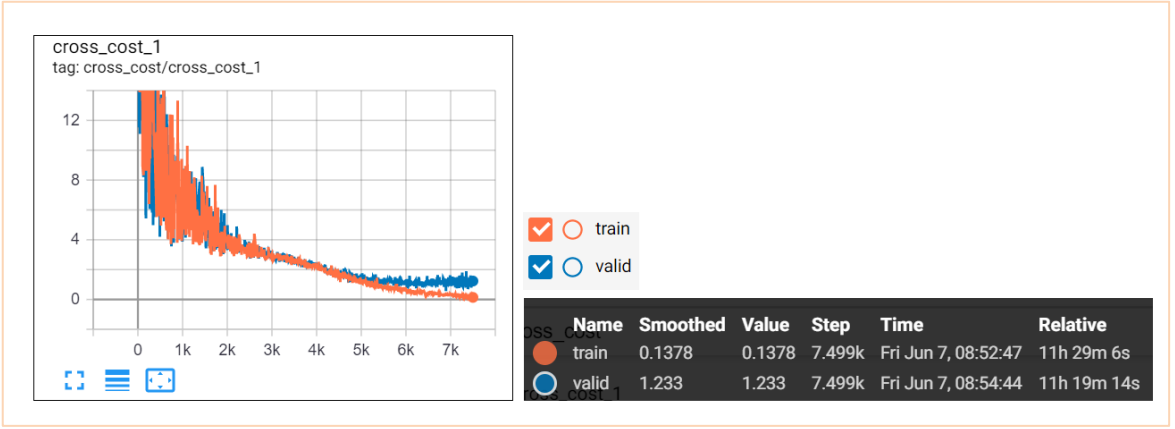

Hình 34 Giá trị lỗi của mạng số 4 trong quá trình nhận diện 48 địa danh

Số lượng ảnh dùng huấn luyện mạng 1200x48 ảnh, số lượng anh dùng cho kiểm chứng lại mạng là 400x48 ảnh. Số lần lặp là 50 cho toàn bộ dữ liệu ảnh đầu vào. Hệ số học (learning rate) là 1E-4.

Giá trị của độ chính xác tăng và giá trị lỗi giảm trên hai tập dữ liệu huấn luyện va tập dữ liệu kiểm thử. Tuy nhiên ở gia đoạn cuối của quá trình huấn luyện, độ chính xác trên tập huấn luyện tăng trong khi trên tập kiểm thử bị chững lại

cho thấy mô hình đang có dấu hiệu bị over-fitting. Mạng cần tăng tỉ lệ dropout hoặc áp dụng nhiều kỹ thuật tránh over-fitting khác.

4.6 Tổng kết toàn bộ quá trình thử nghiệm

Quá trình thử nghiệm đối với từng mạng cùng với việc điều chỉnh tham số số học, cấu trúc mạng , sử dụng kỹ thuật tránh overfitting. Em chọn ra được hai mô hình có độ chính xác tốt nhất đó là mô hình xây dựng dựa trên mạng lenet-5 và mô hình dựa trên mạng resnet-34.

Độ chính xác của hai mô hình này có thể được cải thiện hơn nữa bằng việc tăng thời gian huấn luyện và sử dụng nhiều hơn các kỹ thuật tránh overfitting cho mô hình.

Mộ ưu điểm của hai mô hình trên so với hai mô hình mạng dựa trên mang alexnet và mạng dựa trên mạng vgg-16 là thời gian huấn luyện thấp hơn. Trong khi vẫn đảm bảo được độ chính xác như mong muốn.

Trong chương sau em sẽ ứng dụng mô hình học được

CHƯƠNG 5 – ỨNG DỤNG MÔ HÌNH SAU HUẤN LUYỆN TRONG HỆ THỐNG NHẬN DIỆN ĐỊA DANH

5.1 Biểu đồ ca sử dụng

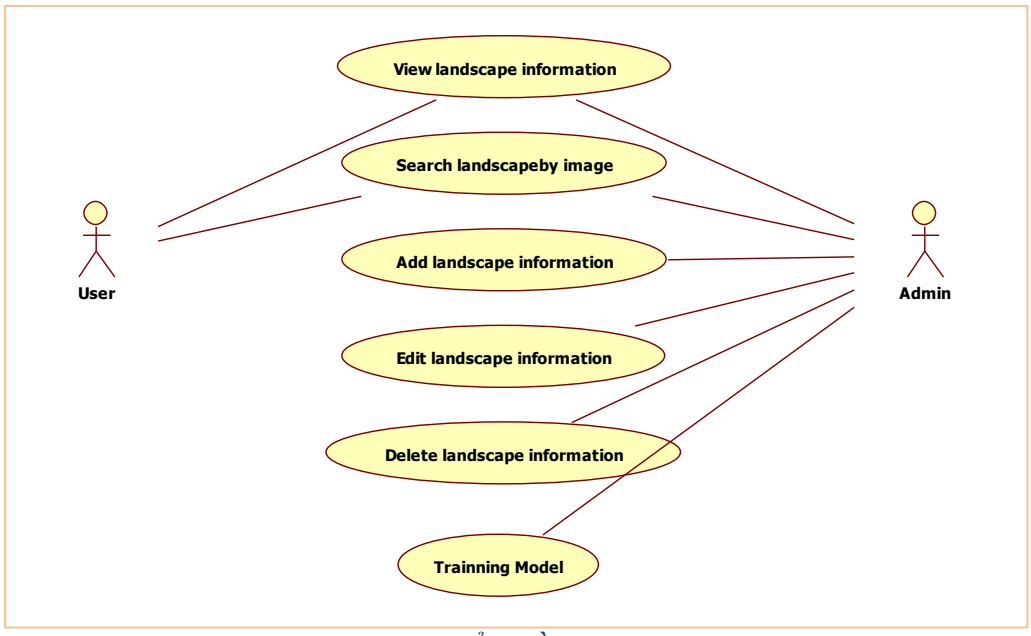

Hình 35 Biểu dồ ca sử dụng

Hệ thống gồm các chức năng cơ bản giúp người dùng có thể xem thông tin và tìm kiếm địa danh bằng hình ảnh. Người quản trị có thêm các quyền liên quan tới trang quản trị như thêm, sửa, xóa thông tin địa danh.

5.2 Biểu đồ lớp

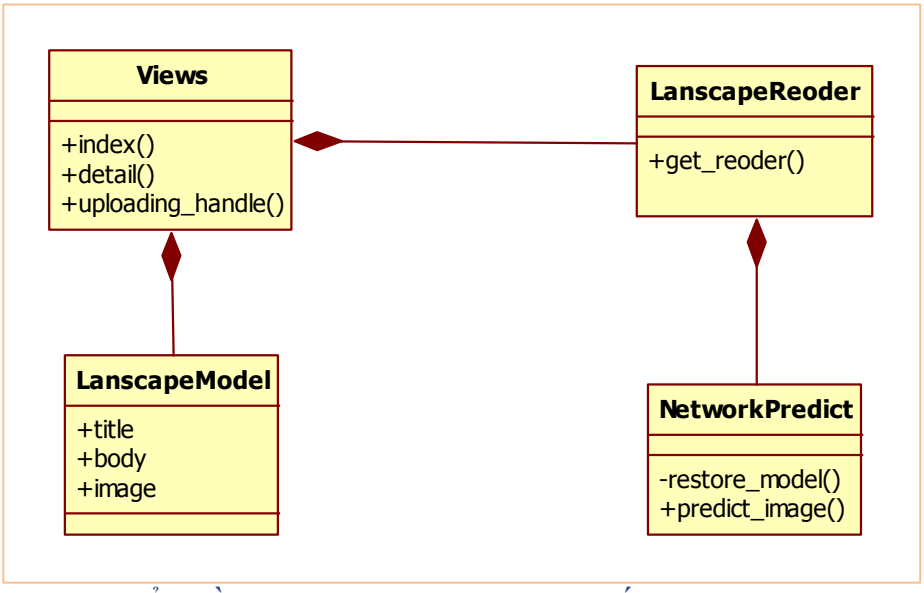

Hình 36 Biểu đồ lớp cho ca sử dụng tìm kiếm thông tin địa danh

5.3 Biểu đồ hoạt động

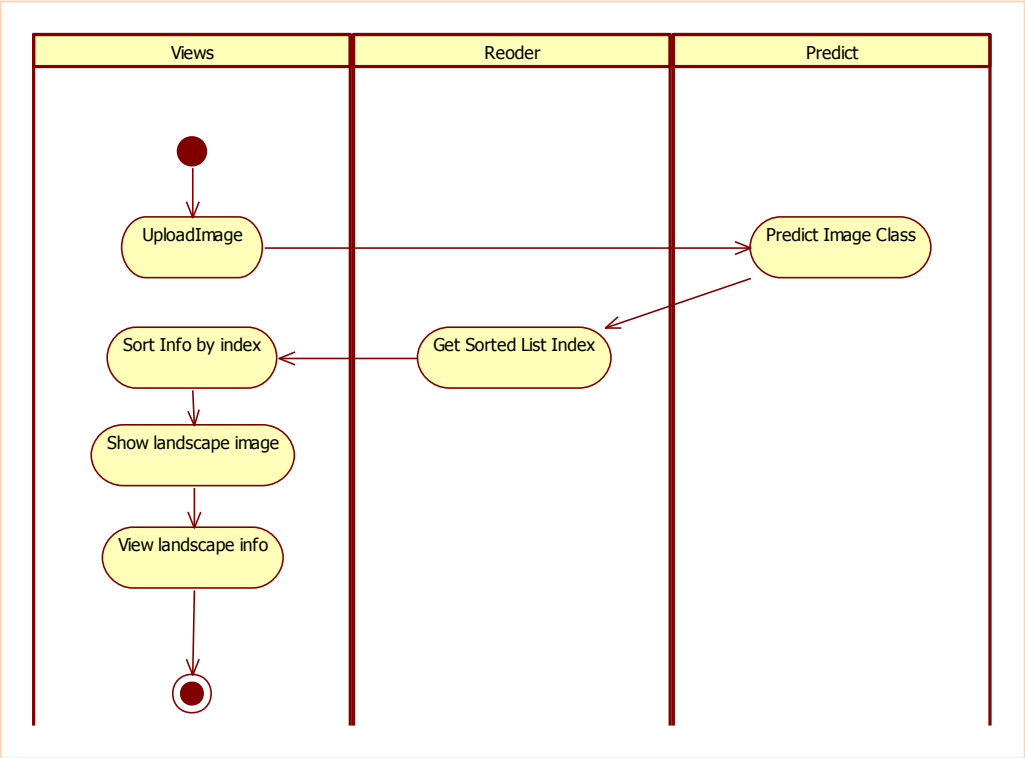

Hình 37 Biểu đồ hoạt động cho ca sử dụng tìm kiếm thông tin địa danh

Chức năng tìm kiếm thông tin địa danh bằng hình ảnh là chức năng quan trọng nhất. Trong đó sử dụng mô hình học máy được đào tạo ở phần 4 để trích chọn đặc trưng, từ đó đưa ra danh sách các địa danh có đặc điểm giống với địa danh được tìm kiếm nhất. Dựa vào đó hệ thống sẽ sắp xếp lại thứ tự danh sách các địa danh và đưa các địa danh có sác xuất giống nhất lên vị trí đầu tiên.

Các chức năng về thêm, sửa, xóa thông tin địa danh được Django hỗ trợ trong trang quản trị của frame work. Người quản trị đăng nhập vào hệ thống và sửa thông tin theo yêu cầu tương ứng.

5.4 Cơ sở dữ liệu địa danh

Cơ sở dữ liệu được sử dụng trong trương trình là cơ sở dữ liệu sqlite được tích hợp sẵn trong Django Frame Work. Với phạm vi chương trình thì cơ sở dữ liệu sqlite đủ đáp ứng được nhu cầu sử dụng cũng như tính gọn nhẹ của cơ sở dữ liệu.

Dưới đây là bảng sữ liệu thông tin địa danh trong cơ sở dữ liệu.

Tên trường	Kiể dữ liệu	Ghi chú
id	interger	primary key
title	varchar(1000)	
body	text	
date	datetime	
num	interger	
image	varchar(100)	

Bảng 8 Bảng dữ liệu địa danh

Trường dữ liệu "title" được dùng để lưu tên của địa danh, trường dữ liệu "body" được dùng để lưu mô tả cũng như cung cấp thông tin chi tiết về địa danh. Trường dữ liệu num để lưu thông tin về ID của địa danh, trường này dùng để tra cứu thông tin địa danh sau khi hàm nhận diện địa danh trả về kết quả là các ID của các địa danh theo thứ tự từ gần giống nhất với đặc điểm địa danh được tìm kiếm. "Image" là trường lưu đường dẫn ảnh minh họa cho địa danh, ảnh minh họa được lưu tại một thư mục trên server.

Tiếp theo là bảng chứa tài khoản người dùng của website

Tên trường	Kiểu dữ liệu	Ghi chú
id	interger	primary key
password	varchar(128)	
last_login	datetime	
is_superuser	bool	
username	varchar(150)	
first_name	varchar(30)	
email	varchar(254)	
is_staff	bool	
is_active	bool	
date_joined	datetime	
last_name	varchar(150)	

Bảng 9 Bảng thông tin người dùng

Bảng được Django hỗ trợ tạo ra trong hệ thống admin, trong đó các trường quan trọng như is_superuser, is_staff được dùng để phân biệt tài khoản admin và user thông thường. Trong đồ án này thông tin user em đang để chỉ gồm một tài khoản admin để đăng nhập vào trang quản trị từ đó thêm, sửa xóa các thông tin về địa danh.

5.4 Giao diện trang web

Dưới đây là kết quả xây dựng hệ thống với chức năng tím kiếm thông tin bằng hình ảnh. Hình ảnh người dùng upload lên và hệ thống nhận diện sau đó trả về thông tin của địa danh tương ứng.

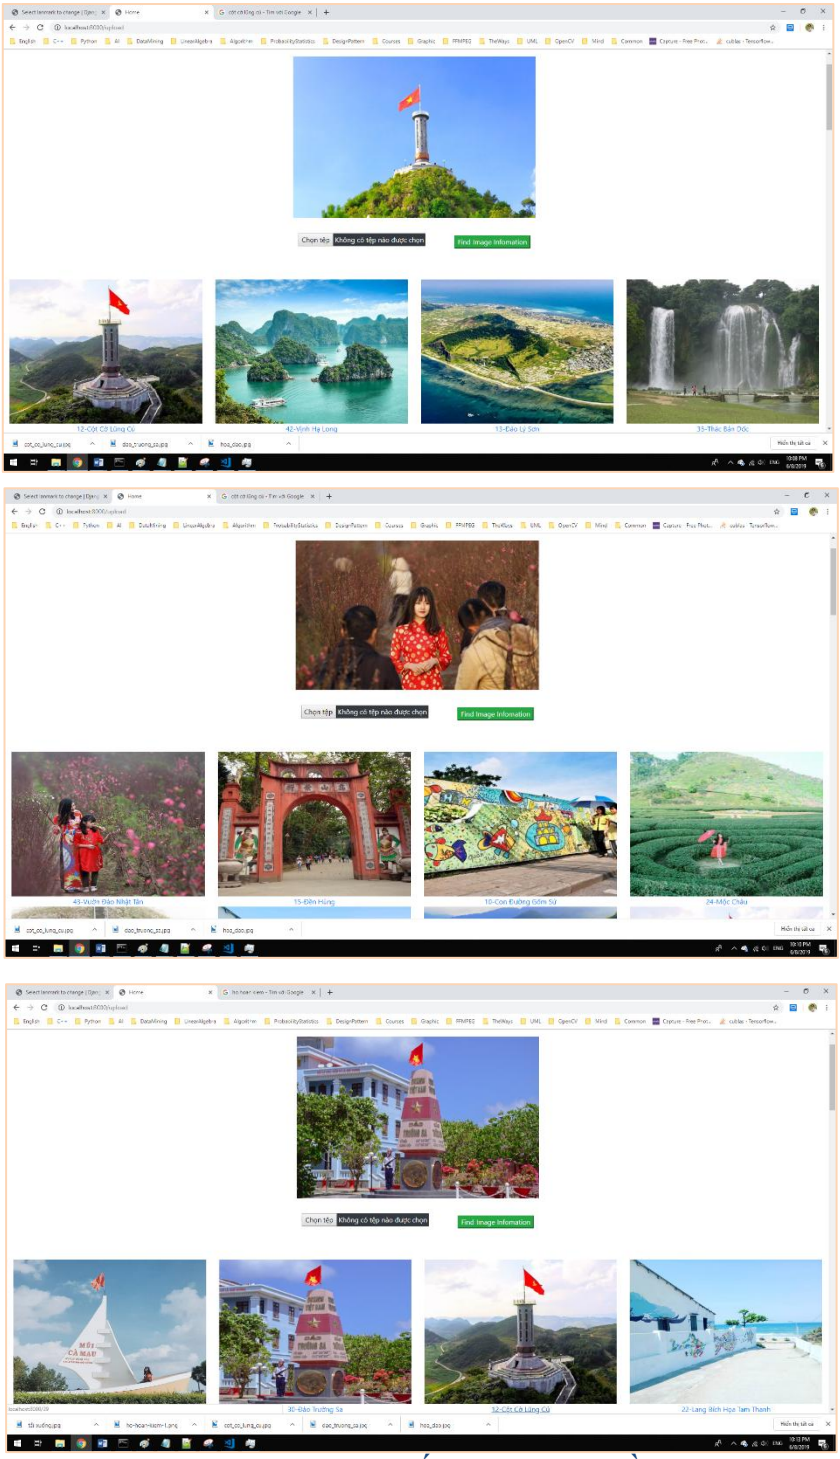

Hình 38 Trang web tìm kiếm địa danh bằng hình ảnh

CHƯƠNG 5 – KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1. Kết luận

Do thời gian huấn luyện mô hình lâu cũng như giới hạn về thời gian. Việc huấn luyện mô hình nhận dạng địa danh hiện tại cho kết quả tốt nhất là 90% với đầu ra 5 địa danh và 73% với kết quả phân loại 48 địa danh. Kết quả phân loại 48 địa danh vẫn còn có thể cải thiện thêm được ít nhất là bằng cách tăng thời gian huấn luyện do như em đã trình bày xu hướng của đồ thị độ chính xác trên mô hình dựa trên mạng lenet-5 và resnet-34 vẫn đang theo chiều tăng. Cùng với đó độ chính xác trên tập huấn luyện và trên tập kiểm thử vẫn đang gần nhau giúp mô hình tránh được lỗi phổ biến là hiện tượng over-fitting.

Trang web ứng dụng mô hình được huấn luyện cho hoạt động ổn định. Mô hình sau khi huấn luyện cùng với trang web có thể chạy trên máy cấu hình thấp chỉ cần điều kiện là trong môi trường có django và tensorflow giúp cho việc triển khai trong thực tế thuận tiện.

Thời gian đáp ứng của trang web nhận diện hình ảnh là khoảng 2 giây, hiện nay trang web nhận diện đang hoạt động theo mô hình web tĩnh.

6.2. Hướng phát triển

Hướng phát triển sẽ nâng cao độ chính xác của việc nhân diện địa danh bằng việc tập trung tối ưu các tham số trên hai mô hình dựa trên mạng lenet-5 và resnet-34 do hai mô hình này cho thấy ưu điểm nổi trội là thời gian huấn luyện mạng ngắn hơn hai mô hình còn lại trong khi vẫn đảm bảo độ chính xác. Ngoài ra em sẽ sử dụng nhiều kỹ thuật tối ưu mạng khác như L2 regularization … cùng với các kỹ thuật augmentation trên tập dữ liệu.

Bổ xung vào dữ liệu nhiều địa danh nổi tiếng hơn thay vì đang dùng là 48 địa danh.

Tối ưu lại trang web để chuyển trang web về dạng web động giúp cho trang web hoạt động trơn chu hơn.

TÀI LIỆU THAM KHẢO

1. Giancarlo Zaccone, Getting Started with TensorFlow, published by Packt Publishing Ltd , first published: July 2016

2. https://www.tensorflow.org/tutorials/

3. https://docs.djangoproject.com/en/2.2/

4. https://www.learnopencv.com/understanding-feedforward-neural-networks/

5. https://towardsdatascience.com/applied-deep-learning-part-4-convolutional-neural-networks-584bc134c1e2

6. https://www.mathworks.com/videos/introduction-to-deep-learning-what-are-convolutional-neural-networks--1489512765771.html

7. https://medium.com/machine-learning-bites/deeplearning-series-convolutional-neural-networks-a9c2f2ee1524

8. https://www.jefkine.com/general/2016/09/05/backpropagation-in-convolutional-neural-networks/

9. https://www.kaggle.com/shivamb/cnn-architectures-vgg-resnet-inception-tl

10. https://www.learnopencv.com/number-of-parameters-and-tensor-sizes-in-convolutional-neural-network/

11. https://indoml.com/2018/03/07/student-notes-convolutional-neural-networks-cnn-introduction/

12. https://towardsdatascience.com/deep-learning-framework-power-scores-2018-23607ddf297a